

Qué compra y cuánto paga el Estado

Auditoría nacional de la capa de producto en las compras públicas de Chile, 2017–2026

Informe Final · Proyecto Capstone

Curso de Big Data · Samsung Innovation Campus 2026

Jeancarlo Cuesta

Trabajo individual, autorizado por escrito por el profesor el 2 de septiembre de 2026

Fecha de entrega: 7 de septiembre de 2026

Defensa final: 9 de septiembre de 2026

Autor: Jeancarlo Cuesta.

Trabajo: individual.

Defensa: 9 de septiembre de 2026.

Término	Definición
Licitación	El aviso con el que el Estado dice «necesito comprar esto» y pide ofertas. Lo redacta una persona del organismo comprador, escribiendo línea por línea qué necesita.
Orden de compra	El documento con el que el Estado efectivamente compra y se compromete a pagar. La plataforma la genera sola, copiando lo que ya estaba declarado antes.
Línea	Cada renglón de esos documentos: un producto, su cantidad y su precio. Este trabajo cuenta líneas, no documentos, porque el código de producto vive en la línea. Es la decisión de diseño que hace posible todo lo demás.
Convenio Marco	Una tienda dentro de la plataforma. Un proveedor ganó antes el derecho a tenerla y cargó su catálogo una sola vez; después, el organismo entra, elige y compra con un clic, sin escribir nada.
Código de producto (o «código ONU»)	Un número de 8 dígitos que dice qué es lo que se compró, tomado de un catálogo de 18.881 códigos. Es la variable que este trabajo mide de principio a fin.
Especificación	El texto libre con el que quien compra describe el producto de esa línea. Es la única evidencia independiente que existe para comprobar si el código está bien puesto.
Circular	Una línea es circular cuando su texto es una copia del nombre del código. Entonces el texto ya no comprueba nada: repite el código con otras palabras. Es una definición de este trabajo, no una categoría oficial.
Evaluable	Una línea es evaluable cuando tiene texto, ese texto no es relleno y no es circular. O sea: cuando la pregunta «¿el código corresponde a lo que se compró?» se puede llegar a hacer.
Baseline nulo	Cuánto habría dado el resultado por pura casualidad. Se calcula barajando los datos al azar y repitiendo exactamente la misma medición. Sin él, una cifra alta no significa nada.
Alerta, no infracción	La doctrina del trabajo. Todo lo que este sistema produce son casos que habría que revisar, nunca la afirmación de que alguien hizo algo mal.

Las etiquetas de color que acompañan cada cifra. **[MEDIDO]** quiere decir que el número salió de correr el código sobre los datos reales, y lleva el identificador de la corrida que lo produjo. **[FUENTE]**, que se verificó en un documento oficial, con su fecha de consulta. **[POR VERIFICAR]** marca un hueco declarado, que no se presenta como hecho. Y **[DESCARTADO]**, algo que se midió, no pasó el criterio fijado de antemano y por lo tanto no se cita en ninguna parte.

Contenido

- Resumen ejecutivo
- 1 · Introducción
 - 1.1 · Información de Contexto
 - 1.2 · Motivación y Objetivo
 - 1.3 · Integrantes y Asignación de Roles
 - 1.4 · Cronograma e Hitos
- 2 · Ejecución del Proyecto
 - 2.1 · Descripción del Escenario Simulado
 - 2.2 · Selección y Descripción de los Datasets
 - 2.3 · Pipeline de Ingesta de Datos
 - 2.4 · Procesamiento de Transformación de Datos
 - 2.5 · Consulta de Datos e Insights
- 3 · Resultados
 - 3.1 · Scripts y Código de Ingesta de Datos
 - 3.2 · Scripts y Código de Transformación de Datos
 - 3.3 · Descripción y Muestra de los Datasets Transformados
 - 3.4 · Visualización de Datos de los Resultados de Consulta
 - 3.4.1 · Pregunta 1: ¿sabe el Estado qué compra?
 - 3.4.2 · Pregunta 2: ¿cambió cuando la ley lo exigió?
 - 3.4.3 · Pregunta 4, el hallazgo principal
 - 3.4.4 · Pregunta 3, cuánto cuesta no saberlo, y los 30 casos abiertos a mano
 - 3.4.5 · Calidad del dato
 - 3.4.6 · El método a prueba
- 4 · Impacto Proyectado
 - 4.1 · Logros y Beneficios
 - 4.2 · Mejoras Futuras
- 5 · Revisión y Comentario de los Integrantes
- 6 · Revisión y Comentario del Instructor
- Anexo A · Cifras citadas y su corrida de origen

Resumen ejecutivo

El Estado publica qué compra, pero en la mayoría de los casos ese dato no se puede comprobar.

Chile publica cada orden de compra y cada licitación del Estado en datos abiertos. Desde el 12 de diciembre de 2024, además, la ley obliga a clasificar y codificar cada bien y servicio transado. Este trabajo pregunta algo que hasta ahora nadie había medido a escala nacional: ¿esa capa de producto sirve para auditar qué compró el Estado?

La respuesta corta es que no, y el motivo no es el que se esperaría. No es que los organismos codifiquen mal: cuando se puede comparar el código de la orden de compra contra el de su licitación de origen, coinciden en el 94,44 % de los casos, contra un 1,38 % que daría el azar. El problema es anterior: en la mayoría de los procesos la pregunta no se puede hacer, porque la licitación nunca declaró una capa de producto contra la cual comparar, y porque el texto libre que debería describir la línea es, cada vez más, una copia del propio nombre del código.

Los ocho resultados que este informe sostiene

Resultado	Cifra	Estado
Consistencia lic↔OC: el código declarado en la OC contra el de su licitación	94,44 % vs 1,38 % del azar	[MEDIDO]
El titular real de esa pregunta: licitaciones que declaran a lo más un código	80,08 %	[MEDIDO]
El efecto de la ley: último año sin obligación vs. primer año con ella	+0,28 pp	[MEDIDO]
Lo que la ley no tocó: la caída de verdad, entre 2019 y 2022	-10,22 pp	[MEDIDO]
El hallazgo principal: circularidad del texto en Convenio Marco	6,65 % → 99,86 %	[MEDIDO]
El dinero: gasto saneado de la década; concentración en 300 códigos	89,4 billones · 72,49 %	[MEDIDO]
Los 30 casos abiertos a mano: códigos válidos que designan otro producto	18 de 30 (60,0 %)	[MEDIDO]
Validación externa: órdenes de compra capturadas de las que ChileCompra declara para 2024	98,25 %	[MEDIDO]

Los cinco hallazgos, en orden de importancia

1. La licitación casi nunca dice qué se está comprando. Una licitación se escribe en líneas: una línea por producto, y cada línea debería traer su propio código. **El 80,08 % de las licitaciones trae, en total, un solo código de producto o ninguno**, sin importar cuántas cosas distintas esté comprando. Dentro de ese 80,08 % hay un 13,33 % que este trabajo llama *testimonial*: la licitación sí tiene varias líneas, pero todas repiten el mismo código, es decir, veinte líneas etiquetadas «papel» aunque una sea papel, otra lápices y otra cuadernos.

Esto es lo que rompe la comparación. Comparar significa poner al lado el conjunto de códigos que declaró la licitación y el que declara su orden de compra, y ver si calzan. **Si la licitación aporta un solo código y la orden aporta doce, no hay nada que poner al lado:** no se puede saber cuál de esos doce era el que la licitación tenía en mente, ni si los otros once corresponden a lo que se licitó o a otra cosa. La comparación no da un resultado

malos; no da ningún resultado en absoluto. **El hallazgo no es que los códigos coincidan poco: es que en cuatro de cada cinco procesos la comparación ni siquiera se puede intentar.**

2. La obligación legal no movió el indicador, y lo que sí se movió ocurrió antes. Entre el último año sin obligación de codificar (2024) y el primer año completo con ella (2025), el indicador de evaluabilidad se mueve 0,28 puntos porcentuales. Pero la serie completa muestra que la caída grande (de 10,22 puntos) ocurrió entre 2019 y 2022, se detuvo en 2023, y ya había terminado de ocurrir cuando la norma entró en vigencia.

3. Todo el deterioro del texto es un mecanismo, no el mercado. En Convenio Marco, la fracción de líneas cuyo texto libre es una copia del nombre del producto pasa de 6,65 % en 2019 a 99,86 % en 2026, y se queda pegada ahí desde 2023. La orden de compra ordinaria (el tipo SE, «sin emisión automática», donde la especificación la escribe una persona) mejora en el mismo período. **Donde la especificación la escribe una persona, la circularidad cae; donde la genera el catálogo de la plataforma, sube hasta el 99,86 %.**

4. Casi toda la plata pasa por muy pocos códigos. El catálogo obligatorio tiene 18.881 códigos de producto, y el Estado usó 17.117 de ellos en la década: casi todos. Pero **el dinero no se reparte como se reparten los códigos.** De los 89,4 billones de pesos gastados, **trescientos códigos (de esos 17.117) concentran el 72,49 % del gasto.** Los diez primeros, solos, concentran el 28,35 % moviendo apenas el 1,26 % de las líneas. Dicho en una frase: **tres de cada cuatro pesos del Estado pasan por trescientos códigos**, y son justamente esos trescientos los que más conviene tener bien declarados, porque son los que mueven la plata.

5. Abiertos a mano, los códigos son válidos y describen otra cosa. De 30 casos revisados uno por uno contra el catálogo, **los 30 códigos declarados existen y 18 designan un producto distinto del que el texto de la línea dice que se compró.** Un control de validez de formato (el que haría cualquier sistema) no detecta ninguno de esos 18.

Freno doctrinal:

Lo que este pipeline produce son **alertas estadísticas, no determinaciones de irregularidad.** Que una línea no sea auditable con lo publicado no prueba que se haya comprado otra cosa, ni que alguien haya codificado mal, ni que un organismo incumpla. Por eso este informe no contiene ningún ranking nominal de organismos ni de proveedores: todo se agrega por sector, mecanismo, tramo de monto o año.

1. Introducción

Todo el mundo mide con quién contrata el Estado; nadie mide qué compra.

1.1 · Información de Contexto

La literatura chilena sobre compras públicas está bien poblada, y está poblada de un solo tipo de pregunta: **competencia y concentración.** Cuántos oferentes hay por licitación, qué proporción se adjudica por trato directo, cuánto se concentra el mercado de proveedores. La Fiscalía Nacional Económica lo midió en 2020; el BID y Espacio Público lo midieron en 2019; hay estudios universitarios que lo repiten con distintos cortes.

Ese ángulo está cubierto, y competir con él no habría sido un aporte. El hueco real está en otro lado y es más básico: la capa de producto, es decir, el código ONU/UNSPSC a nivel de línea, que dice qué se compró y no a quién.

Cómo funciona Mercado Público, en simple

Las cifras de este informe hablan de «licitación», «orden de compra» y «Convenio Marco» como si fueran obvias. Para un lector sin trato con la plataforma no lo son, y la distinción entre ellas es la que sostiene todo el análisis que sigue. En Mercado Público hay, en esencia, tres caminos de compra, y cada uno reparte distinto quién escribe el dato y en qué momento aparece.

De qué dato habla este informe: quién escribe el detalle de cada línea (su texto y su código de producto) y en qué momento del proceso lo escribe. [FUENTE]

Momento	Quién lo hace	Manual o automático
Redactar las bases de una licitación (qué se compra, en cuántas líneas, con qué código ONU por línea)	El organismo comprador	Manual: la persona escribe el texto y elige el código del catálogo
Publicar el catálogo de Convenio Marco (nombre del producto, código ONU, precio)	El proveedor adjudicado del convenio	Manual, pero una sola vez por producto de catálogo, no por compra
Emitir la orden de compra al adjudicar una licitación	La plataforma	Automático: se genera con los datos de la oferta adjudicada
Emitir la orden de compra en Convenio Marco	La plataforma	Automático: el comprador solo hace clic en «comprar» sobre el catálogo ya publicado

Licitación pública es el camino donde una persona redacta las bases: describe qué necesita, en cuántas líneas y con qué código ONU asigna a cada una. Es trabajo manual, línea por línea, y es la fuente de las cifras de las Preguntas 1 y 4 de este informe.

De la adjudicación a la orden de compra es un paso que la plataforma hace sola: una vez que el organismo adjudica una oferta, el sistema genera automáticamente la orden de compra correspondiente, copiando los datos de esa oferta [FUENTE]. Por regla general nadie vuelve a escribir el detalle de la compra en ese momento: se hereda de lo que ya se declaró en la licitación o, en Convenio Marco, del catálogo.

Aclaración:

Que el detalle se herede no impide que aparezcan códigos nuevos por el camino: **hay órdenes de compra que declaran un código de producto que su licitación de origen nunca mencionó**. No es una excepción anecdota, y no queda fuera de la medición: es exactamente lo que cuenta el complemento del 94,44 % de §3.4.1. Esa cifra no mide «calzan los códigos» en abstracto, mide algo más preciso: que ningún código de la orden de compra quedó fuera del conjunto de códigos que había declarado su licitación. Todo lo que no entra en ese 94,44 % es, por definición, una licitación cuya orden trajo al menos un código ajeno.

Además, hay una segunda evidencia, esta vez caso a caso: el **Grupo 2 de los 30 casos abiertos a mano** (§3.4.4) está construido a propósito con líneas donde el código de la orden *no* figuraba en su licitación. De los 10 que se abrieron uno por uno, **8 declaran un código que describe otro producto**, contra 4 de 10 en el grupo donde el código sí venía de la licitación. La dirección es la esperable (donde el dato venía heredado, es mejor), pero con diez casos por grupo **no alcanza significancia y este informe no afirma que la diferencia sea real** (§3.4.4).

Convenio Marco es un circuito distinto, y es la pieza que más explica los hallazgos de este informe. Aquí no hay licitación por compra: un proveedor ganó una licitación general para operar una «tienda» dentro de la plataforma y cargó su catálogo de productos, cada uno con su propio código ONU y precio, una sola vez. Un organismo que necesita ese producto no redacta bases: entra a la tienda, elige el ítem del catálogo y compra con un clic **[FUENTE]**. La orden de compra que resulta no fue redactada por nadie en ese momento: es una copia del ítem de catálogo.

Aclaración:

Todo lo que este trabajo mide depende de esta separación entre lo que una persona escribe (licitación, y la especificación de texto de una orden SE) y lo que la plataforma genera sola (la orden de compra al adjudicar, y todo Convenio Marco). Cuando el hallazgo dice que «el 80,08 % de las licitaciones declara a lo más un código», habla del paso manual. Cuando dice que «Convenio Marco pasa a 99,86 % de texto circular», habla del paso automático. **Son dos mecanismos distintos, y el informe no los mezcla.**

[FUENTE] Mecanismo verificado en tres fuentes primarias de ChileCompra, consultadas el 3 de septiembre de 2026: la guía oficial «Creación de un proceso de Licitación» (por línea, código de producto y categoría obligatorios); chilecompra.cl/convenio-marco/ (catálogo cargado por el proveedor, compra por selección directa); y la Directiva N.º 1 de ChileCompra (chilecompra.cl/wp-content/uploads/2016/11/directiva-n01.pdf), que confirma que la orden de compra se genera automáticamente al adjudicar, con los datos de la oferta adjudicada.

El regulador controla el proceso, no la descripción del objeto comprado

El propio regulador tiene un Observatorio de compras públicas con un sistema de monitoreo automatizado. **Son quince reglas de negocio, y ninguna de las quince toca la calidad del código de producto ni la descripción del bien o servicio adquirido [FUENTE].**

Detalle: las quince alertas del monitoreo automatizado (texto oficial)

1. Garantía de seriedad de la oferta mayor al 3 %
2. Garantía de fiel y oportuno cumplimiento distinta al 5 % del contrato
3. Plazo insuficiente para formular preguntas en el foro de la licitación
4. Tiempo insuficiente entre cierre de recepción y adjudicación de proveedor
5. Plazo insuficiente entre la publicación de respuestas y el cierre de recepción de ofertas
6. No se responden las preguntas del foro de consultas
7. No se responden reclamos por irregularidad
8. No se considera el criterio económico (precio) en la evaluación de ofertas
9. No se adjudica la licitación en los plazos establecidos ni se forma nueva fecha
10. Disminución del plazo de publicación de la licitación sin justificación
11. Tipo de licitación no concuerda con el monto estimado
12. Sin plazo suficiente para visita a terreno

13. No adjunta resolución que aprueba la compra directa
14. Fragmentación de Compras Ágiles para eludir la modalidad o los umbrales
15. Gran Compra en Convenio Marco sin evidencia de intención formal

[FUENTE] chilecompra.cl/alertas-automatizadas-del-observatorio/, consultada y transcrita el 6 de septiembre de 2026. Las quince reglas son de plazos, garantías, evaluación, documentación y umbrales de modalidad: **todas procedimentales**. Ninguna evalúa si el código de producto declarado corresponde a lo comprado.

Por qué el código de producto no es un detalle técnico

El código ONU no es un metadato inerte de archivo. En Mercado Público cumple una función operativa verificada en fuente primaria [FUENTE]: ChileCompra vincula explícitamente el código ONU a la selección de rubro del proveedor, y el rubro del proveedor es la base de las notificaciones automáticas de nuevas oportunidades y de la búsqueda «Todas las adquisiciones de mis rubros».

Alcance y límites:

Los dos hechos anteriores están verificados por separado en fuentes oficiales, pero **ningún documento oficial los une en una sola frase**. La conclusión de que un código mal declarado reduce la difusión efectiva de una oportunidad es una inferencia razonable sobre dos hechos verificados, y se presenta como tal, no como cita directa.

El ancla legal: artículo 20 bis

Desde el 12 de diciembre de 2024 existe un mandato legal explícito sobre exactamente la variable que este trabajo mide [FUENTE]. El artículo 20 bis de la Ley 19.886, incorporado por la Ley 21.634 (publicada el 11 de diciembre de 2023), dispone:

Art. 20 bis, Ley 19.886

«En el sistema de información y gestión señalado se deberán clasificar y codificar los bienes y servicios transados a través de él, y permitir el acceso público a la información que señale el reglamento, respecto de la adquisición de cada tipo de bien o servicio, en formato de datos abiertos.»

Aclaración: el artículo 20 bis no menciona los términos «ONU» ni «UNSPSC», verificado sobre el texto vigente de la Ley 19.886 el 21 de agosto de 2026. Es ChileCompra quien identifica el catálogo ONU como el clasificador exigido, en su página oficial sobre el artículo 20 bis. La distinción importa: un incumplimiento del catálogo ONU no equivale, sin más, a un incumplimiento legal.

Esto cambia el encuadre del trabajo: la pregunta deja de ser «¿cómo evolucionó la consistencia?» y pasa a ser «¿la **obligación legal produjo verificabilidad?**». Con una consecuencia metodológica que atraviesa todo el informe: **2017 a 2024 son años anteriores a la obligación, 2025 es el primer año completo bajo ella y 2026 es parcial**. Toda comparación entre años cruza una frontera jurídica y este informe la dibuja explícitamente, en el texto y en cada gráfico de serie.

1.2 · Motivación y Objetivo

La motivación es la asimetría entre lo que el Estado publica y lo que se puede comprobar con lo publicado. Chile publica más datos de compras públicas que casi cualquier país de la región, y desde diciembre de 2024

tiene además una obligación legal de codificar lo que compra. Si esa combinación funcionara, cualquier ciudadano podría preguntarse «¿cuánto pagó el Estado por este producto y cuánto pagó otro organismo por el mismo?» y obtener una respuesta. El objetivo de este trabajo es **medir, a escala nacional y sobre la década completa, si esa pregunta tiene respuesta** y, cuando no la tiene, identificar exactamente dónde se rompe la cadena.

El objetivo se descompone en cuatro preguntas de investigación, fijadas antes de correr el pipeline:

El arco del trabajo: las cuatro chocan con la misma pared

#	Pregunta	Dónde se responde
P1	¿Sabe el Estado qué compra? ¿La orden de compra declara el mismo código ONU que su licitación de origen?	§3.4.1
P2	¿Cambió cuando la ley lo exigió? Comportamiento del indicador alrededor del 12 de diciembre de 2024.	§3.4.2
P4	¿El código se puede verificar contra el texto de la línea? Validez de la codificación publicada.	§3.4.3
P3	¿Cuánto cuesta no saberlo? Dispersión de precio del mismo producto entre organismos.	§3.4.4

No son cuatro anexos: son un arco. Las cuatro chocan con la misma pared, que es que la capa de producto casi no se declara, y el informe las presenta en el orden en que esa pared se hace visible. **La Pregunta 3 va última porque es la que depende de que las otras tres hayan fallado:** solo se puede comparar precios del mismo producto si el código identifica el producto.

1.3 · Integrantes y Asignación de Roles

Trabajo individual. Jeancarlo Cuesta ejecutó las cinco funciones que en un equipo se reparten: ingeniería de datos (descarga, esquema común, particionado Parquet), desarrollo del pipeline en Spark, diseño estadístico (baselines nulos, placebos, intervalos de confianza, estratificación y reponderación), verificación de fuentes normativas, y redacción de los tres entregables.

Nota metodológica:

Un equipo tiene revisión cruzada por construcción; un trabajo individual no. Este proyecto lo compensó con tres mecanismos explícitos, que están documentados en §2.4 y §3.4.6: **un régimen de marcas de evidencia** que impide que una cifra sin corrida entre al informe; **criterios de validación predeclarados**, que en un caso obligaron a descartar una implementación propia entera con el número ya calculado; y **auditorías adversariales cifra por cifra contra las salidas crudas**, corridas antes de cada entregable: la del 24 de agosto encontró seis discrepancias reales sobre 136 cifras, y la del 6 de septiembre encontró once sobre 259. **Ninguna de las dos la corrió la misma persona que escribió las cifras sin volver al archivo crudo.**

1.4 · Cronograma e Hitos

El proyecto corrió del 5 de agosto al 9 de septiembre de 2026. La secuencia no fue lineal: **tres de los hitos son correcciones de resultados propios**, y están en el cronograma porque son parte del trabajo, no accidentes que convenga esconder.

Fecha	Hito
Del 5 al 20 de agosto	Etapas 1 · Ingesta. Descarga mes a mes del portal de datos abiertos, esquema común, consolidación en Parquet particionado. Gates G1 a G6 de admisibilidad del universo.
21 de agosto	Primera corrida completa (run_id 1314c4f6d481): universo, Preguntas 1 y 2, y el capítulo de dinero.
23 y 24 de agosto	Cascada de texto evaluable (G7) y circularidad por mecanismo: el hallazgo principal. Cinco corridas independientes del mismo cálculo para probar determinismo.
24 de agosto	Primera auditoría adversarial. 136 cifras contra salidas crudas arrojaron seis discrepancias reales , dos de ellas en un documento que se declaraba verificado. Corregidas.
26 de agosto	Tres tamices de coherencia código↔texto sobre muestra estratificada de 300 líneas con patrón oro humano. Una implementación alternativa se descarta entera por no pasar su criterio predeclarado.
1 de septiembre	Cierre del trío G6 (run_id CAP-3-BIS): se escribe la celda que faltaba porque la cifra anterior era un literal escrito a mano dentro de un <code>print()</code> .
3 de septiembre	Cuatro cierres estadísticos: intervalo de confianza del delta de P2, estudio de asociación con número de oferentes (Mantel-Haenszel + placebo), concordancia caso a caso entre tamices (κ de Cohen), y G6 integrado.
6 de septiembre	Segunda auditoría adversarial (259 cifras, de las cuales 11 correcciones y 9 respaldos declarados faltantes) y triage de los 30 casos abiertos a mano , que desbloquea la Pregunta 3. Repositorio del proyecto creado y subido.
7 y 8 de septiembre	Dashboard de tres páginas y tres ensayos cronometrados de la defensa.
9 de septiembre, 18:30 horas	Defensa final.

2. Ejecución del Proyecto

Un pipeline reproducible, y un régimen de evidencia que se aplicó contra el propio trabajo.

2.1 · Descripción del Escenario Simulado

Los datos no son simulados: son los datos abiertos reales de Mercado Público, la década completa. Lo que se simula es el rol institucional desde el cual se los interroga, y esa elección determina qué se puede afirmar y qué no.

El escenario es el de una **unidad de análisis de datos dentro de un organismo de control** (una contraloría, el propio Observatorio del regulador, una unidad de periodismo de datos) que recibe un encargo concreto: «*construya un sistema que, usando solamente lo que el Estado ya publica, permita saber qué se compró y a qué precio, y que levante alertas donde eso no se pueda comprobar.*» Nada de acceso privilegiado, nada de pedirle datos a nadie: solo el portal público.

Ese encuadre impone tres restricciones que el proyecto respetó, y son las que explican varias decisiones que de otro modo parecerían timidez:

Las tres restricciones del escenario, y qué cambian

Restricción	Qué obliga
Solo datos abiertos publicados	Ninguna cifra depende de un acceso interno. Todo lo que este informe afirma es reproducible por un tercero con la misma descarga.
El producto es una alerta, no un dictamen	Un organismo de control abre casos; no sentencia. El sistema marca líneas que <i>no se pueden verificar</i> , y nunca concluye que hubo irregularidad.
Sin señalamiento individualizado	Ni ranking nominal de organismos ni de proveedores en informe y presentación: se agrega por sector, mecanismo, tramo de monto, año o percentil.

Freno doctrinal:

«**Alerta, no infracción**». No es una precaución retórica: es el resultado que el trabajo midió. Tres fuentes independientes (dos algoritmos de similitud sobre 300 líneas, un revisor externo de IA sobre 30 casos, y la revisión humana contra el catálogo) coinciden en *detectar* que un código está mal y **casi nunca coinciden en cuál debería ser** (§3.4.3 y §3.4.4). Un sistema que puede marcar pero no puede corregir no tiene autoridad para dictaminar, y ese límite está cuantificado, no supuesto.

2.2 · Selección y Descripción de los Datasets

Tres fuentes, todas públicas. Dos son los datasets transaccionales del portal de datos abiertos de Mercado Público; la tercera es el catálogo de códigos de producto contra el cual se valida.

Universo cargado: de 2017 a 2026, con 2026 parcial. [MEDIDO]

Dataset	Filas	Documentos distintos	Filas por documento (promedio)
Órdenes de compra (una fila = una línea de una orden)	51.451.528	18.927.791	2,72
Licitaciones (una fila = una línea de una licitación)	26.312.405	1.258.615	20,91
Catálogo de códigos de producto (una fila = un código)	18.881	18.881	1,00

[MEDIDO] run_id 1314c4f6d481, reconfirmado en 86a9f215712a

Cómo se lee esa última columna: es un **promedio**, no un valor fijo. Una orden de compra trae *en promedio* 2,72 líneas: hay órdenes de una sola línea y órdenes de cincuenta. Una licitación trae en promedio 20,91 líneas.

El catálogo de códigos da 1,00 porque ahí cada fila es un código distinto, sin repetición posible. Y el número importa: **51,4 millones de líneas corresponden a 18,9 millones de órdenes de compra**, y ese factor de 2,72 es exactamente la información que se pierde si alguien analiza estos datos por documento en vez de por línea.

Por qué el grano es la línea y no el documento

Esta es la decisión de diseño que hace posible todo el trabajo, y conviene explicarla porque casi todos los análisis publicados de compras públicas chilenas usan el documento como unidad. **El código de producto vive en la línea, no en la orden.** Una orden de compra de material de oficina tiene 2,72 líneas en promedio, y cada una debería declarar qué es: papel una, lápices otra. Agregar al documento, es decir, sumar el monto de la orden y quedarse con «una» categoría, destruye exactamente la variable que este proyecto mide. El costo de esa decisión es el volumen: **51,4 millones de filas en vez de 18,9 millones**, y una tabla de licitaciones con 20,91 líneas por clave.

Las columnas que importan, y las que resultaron no servir

Campos usados, por rol en el análisis

Campo	Rol	Estado
codigo_oc codigo_licitacion	claves de enlace entre los dos datasets	usados
codigo_onu (8 dígitos)	la variable central: la capa de producto	usado
especificacion_comprador (texto libre)	única evidencia independiente contra la cual verificar el código	usado
precio_netos × cantidad	gasto por línea	usado
tipo_oc (SE, CM, AG, MC...)	mecanismo de compra: la variable que explica el hallazgo principal	usado
unidad_medida	comparabilidad de precio	12,05 M de líneas sin unidad; 7,27 M dicen «UNIDAD NO DEFINIDA»
monto_total_oc_clp	se probó como reconciliador de montos	[DESCARTADO]: la razón contra el cálculo por línea oscila entre 1,26 y 6,56 sin patrón
FechaAdjudicacion	se probó como marca temporal del proceso	no distingue estimado de observado (ver §3.4.5)

El catálogo de códigos de producto, y su límite declarado

La validación del código exige un catálogo de referencia. Se usó el listado de rubros ONU publicado por ChileCompra en chilecompra.cl/ley-catalogo-onu/: **18.881 códigos, descargado el 21 de agosto de 2026 y reverificado sin cambios (diff, cero diferencias) el 24 de agosto de 2026**. El archivo tiene cuatro niveles jerárquicos (Nivel1 → Nivel2 → Nivel3 → producto) y dos columnas de código que **no son intercambiables**: CodigoProducto, de 8 dígitos, que es el que una línea de compra debe declarar, e IDCategoria, que identifica la clase y no es un código válido de producto. Confundirlos es un error real que este trabajo documentó tres veces en §3.4.4.

Alcance y límites:

El catálogo obligatorio se publica sin versión ni fecha de vigencia [FUENTE]. El archivo no trae número de versión, fecha de vigencia ni resolución que lo apruebe, y la página tampoco las declara. Consecuencia directa sobre lo que se puede afirmar: **los códigos «fuera del catálogo» que este trabajo reporta no se pueden distinguir entre error de codificación y código retirado del catálogo después de la transacción.**

Además, la cifra 18.881 es dato interno de este proyecto, no cifra oficial. La verificación del 21 de agosto de 2026 sobre chilecompra.cl/ley-catalogo-onu/, [licitacion-proveedor/](https://licitacion-proveedor.cl/api/), api/ y el portal de datos abiertos dejó constancia de que **ninguna publica el número de códigos del catálogo ni la versión de UNSPSC que aplica**. El número corresponde al archivo que este trabajo descargó y usó, y se cita como tal.

2.3 · Pipeline de Ingesta de Datos

La ingesta es la **Etapla 1** del proyecto y produce la capa de esquema común sobre la que corre todo lo demás. Cuatro pasos, todos reproducibles:

Etapla 1: de los CSV mensuales del portal al Parquet particionado

Paso	Qué hace	Por qué así
1	Descarga mes a mes de los archivos de órdenes de compra y de licitaciones del portal de datos abiertos, para los diez años	El portal publica por mes. Descargar por mes deja un rastro auditable de qué archivo aportó qué filas, y permite re-descargar un mes solo sin tocar el resto, algo que resultó indispensable en §3.4.5
2	Normalización a un esquema común (local/esquema_comun.py): los encabezados y tipos cambian entre años	Sin este paso, una unión directa de diez años pierde columnas en silencio o las llena de nulos. Es el error más barato de cometer y el más caro de detectar después
3	Consolidación en Parquet particionado por año (_year)	Columnar y comprimido: una consulta que solo lee codigo_onu y especificacion_comprador no paga por las otras 30 columnas. La partición por año permite además medir el efecto de borde del universo
4	Gates de admisibilidad G1 a G6: el universo no se declara cargado hasta que pasa un conjunto de controles de conteo, unicidad de clave y trazabilidad de enlace	Se fijaron antes de cargar. El proyecto no prometió la década completa hasta que los gates la confirmaron

Nota metodológica:

Comparar el año de la partición contra el año de la fecha de creación del documento da una discrepancia del **0,5982 %** (307.775 de 51.451.528 líneas), que sube a **1,79 % en 2026 [MEDIDO]** (run_id 628c163f82e7). Es un artefacto de borde de partición, no un hallazgo sobre el mercado, y es la razón por la cual **2026 se dibuja marcado como parcial en todos los gráficos de serie** y no se compara contra años completos.

2.4 · Procesamiento de Transformación de Datos

La **Etapa 2** (el cuaderno que se entrega con este informe) carga los diez años desde Parquet, los limpia, los cruza y produce todas las cifras citadas. Corre en Databricks sobre Apache Spark. Esta sección describe las cuatro transformaciones que tienen consecuencias sobre los resultados, y el régimen bajo el cual se aceptan sus cifras.

2.4.1 · El régimen de evidencia

Este trabajo adoptó desde el inicio una regla que resultó ser su rasgo más útil: **ninguna afirmación se escribe sin decir de dónde sale**. Cada cifra lleva una marca, y las marcas no son decorativas: dos de ellas *impiden* que la cifra entre a este informe.

Marcas de evidencia y qué obliga cada una

Marca	Significa	Qué debe acompañarla
[MEDIDO]	Calculado sobre los datos reales del proyecto	Archivos usados, fecha de corrida e identificador de corrida
[FUENTE]	Verificado en fuente primaria externa	URL o documento oficial citado, con fecha de consulta
[POR VERIFICAR]	Pendiente de comprobación	Qué consulta lo resolvería. No entra al informe como hecho
[DESCARTADO]	No pasó su criterio predeclarado	Se documenta el descarte. Ninguna cifra suya se cita

Tres corolarios de la regla merecen mención porque cambiaron resultados concretos de este trabajo:

Toda cifra se copia de la salida cruda, nunca se recalcula sobre una tabla ya redondeada. Recalcular a mano un número sobre una tabla impresa con un decimal reproduce el mismo redondeo y da una falsa sensación de confirmación. La auditoría del 24 de agosto encontró ocho cifras publicadas en un documento propio que se declaraban «verificadas a mano» y que no reproducían la salida real.

Un archivo citado que no se puede señalar con una ruta no existe. Esta regla nació de un caso concreto (§3.4.6) y volvió a activarse el 6 de septiembre: la auditoría encontró **cuatro identificadores de corrida citados en el anexo sin un solo byte de salida archivada**. Uno se resolvió archivando la salida; los otros tres están declarados como tales en el Anexo A, no listados como corridas vigentes.

Una auditoría adversarial se corre antes de cada entregable. La del 24 de agosto: 136 cifras auditadas contra las salidas crudas, **seis discrepancias reales**, cinco de ellas en cifras citables y dos dentro de un documento que se declaraba verificado. La del 6 de septiembre: **259 cifras y afirmaciones, 173 reproducen exacto, 24 derivadas verificadas, 11 discrepancias y 9 respaldos faltantes**, todos aplicados en este texto. Cada hallazgo de la auditoría se volvió a comprobar contra el archivo crudo antes de aplicarlo, porque dos de los que parecían graves resultaron falsos: uno decía que la circularidad del vacío era 83,55 % en vez de 83,56 % (era truncamiento y no error: el valor exacto es 83,5553 %), y otro que la κ de Cohen era 0,19 en vez de 0,2521, por una matriz 2×2 mal pareada. **Aplicarlos habría metido al informe dos cifras que no están en ninguna salida.**

2.4.2 · El saneamiento de montos, y su daño colateral medido

El problema, primero. Si se suman todas las líneas tal como vienen publicadas (precio unitario multiplicado por cantidad, solo las que están en pesos chilenos), el gasto de la década da **126,9 billones de pesos** (126.889.600.153.921 CLP). Pero **una sola línea de una sola orden de compra aporta 36,8 billones de esos 126,9**: el 29 % del gasto de diez años del Estado entero, en un renglón. Dejarla dentro deformaría todas las cifras en pesos de este informe, y no por poco.

Cómo se separan esas líneas, y por qué así. Las líneas sospechosas tienen una firma reconocible: *el precio unitario es exactamente igual a la cantidad*. Es lo que ocurre cuando alguien escribe el monto total en la casilla del precio y vuelve a escribir el mismo número en la casilla de la cantidad; al multiplicarlos, el sistema eleva el monto al cuadrado. El filtro busca esa firma (precio idéntico a la cantidad, y ambos por sobre 1.000 pesos) y es **arbitrario, elegido por este trabajo, y declarado como tal**: no existe una regla oficial para esto.

Cuánto saca el filtro. De 50.134.474 líneas en pesos, cumplen la firma **1.331 líneas**: el **0,002655 %**, menos de tres de cada cien mil. Esas 1.331 suman **37.442.070.808.807 pesos** (37,4 billones), el 29,51 % del total crudo. Restadas, el **gasto saneado de la década queda en 89,4 billones de pesos** (89.447.529.345.114 CLP), y esa es la cifra que este informe usa en todos sus cálculos de dinero.

99,98 % [MEDIDO]. La pregunta obligada es si ese filtro no estará botando compras buenas. Está medida, y la respuesta es que casi no bota nada. De los 37,4 billones que el filtro excluye, **el 99,98 % viene de solo dos líneas**. Las otras **1.329 líneas juntas suman 7.292.975.798 pesos**, unos 7.293 millones, el **0,0057 % del gasto de la década**: seis milésimas de un punto porcentual. Y esas 1.329 casi con seguridad no son errores, ya que el precio coincida con la cantidad puede ser pura casualidad, como comprar 5.000 unidades de algo que vale 5.000 pesos cada una. **O sea: el filtro saca dos líneas que sí deformaban todo, y de paso 1.329 que no cambian nada. El costo de equivocarse está medido, y es despreciable.**

Salvedad:

Los montos son nominales, sin deflactar por IPC. El pipeline tiene el paso previsto pero desactivado por falta del archivo de IPC mensual empalmado. La frase que acompaña cualquier monto de este informe es: «*suma de precio neto por cantidad, solo líneas en pesos chilenos, sin ajustar por inflación*».

2.4.3 · El enlace orden de compra ↔ licitación (G6)

Todo lo que sigue depende de poder rastrear una orden de compra hasta la licitación que la originó. Esa métrica se reporta siempre como un trío, nunca como una cifra suelta:

G6 · trazabilidad documental orden de compra ↔ licitación. [MEDIDO]

Variante	Valor	Qué mide
Ajustado por conteo (cifra principal)	99,83 %	Corrige el truncamiento del universo: las OC de los primeros años apuntan a licitaciones anteriores a 2017 que nunca se cargaron
Bruto, sin ajustar	91,01 %	15.381.353 enlazadas de 16.901.188 con clave de licitación
Restringido	66,97 %	Excluye los mecanismos que por diseño normativo no pasan por licitación
Por monto en pesos	70,24 %	La misma pregunta pesando por gasto en vez de por línea

[MEDIDO] run_id 5387564e7d37 · corrida CAP-3-BIS, 1 de septiembre de 2026 · salida cruda archivada en resultados/cap3bis_g6_ajustado_salida_cruda.txt

Nota metodológica: verificación de no circularidad del ajuste G6

El indicador ajustado (99,83 %) no debe confundirse con un cálculo anterior y descartado (CAP-3 v13, denominador 15.359.135) que un documento interno del proyecto (docs/01-RESULTADOS-CORRIDA-1314c4f6d481.md, §3.1) marca como «NO USAR: circular», porque ese cálculo se quedaba primero solo con las órdenes de compra cuya licitación estaba cargada, y después preguntaba qué porcentaje de ellas tenía la licitación cargada: tenía que dar casi 100 % pasara lo que pasara. El «NO USAR» de ese documento es correcto, y se refiere a ese cálculo, no al vigente.

El cálculo vigente (CAP-3-BIS, denominador 15.407.374) no impone ese filtro, y la prueba cabe en tres números. Quedan **1.519.835 líneas sin enlazar**. De ellas, **1.493.814 apuntan a una licitación anterior a 2017**, que nunca se cargó porque el universo de este trabajo empieza en 2017; esas se excluyen con razón, y ese es todo el ajuste. Pero **sobran 26.021 líneas que apuntan a una licitación de 2017 o posterior, que sí estaba cargada, y aun así no la encontraron**. Ese sobrante es la prueba: un cálculo circular no deja sobrantes, porque los habría eliminado antes de contar. Éste deja 26.021.

Tres controles adicionales, verificados sobre la salida cruda archivada: las líneas no enlazadas sumadas año por año dan exactamente 16.901.188 – 15.381.353, o sea la resta cuadra y no se perdió ninguna fila por el camino; la columna que cuenta las claves ilegibles vale **cero en los diez años**, así que ninguna línea quedó fuera por no poder leer su código; y el porcentaje de líneas que apuntan a antes de 2017 cae de **99,56 % en 2017 a 1,76 % en 2026**, que es exactamente la forma que tiene un problema de «el universo empieza en 2017», y no la que tendría un filtro circular, que daría un valor parejo en los diez años.

El valor citado hasta el 1 de septiembre de 2026 era 99,19 %, un literal escrito a mano dentro de un `print()` del cuaderno de respaldo, sin línea de código que lo calculara; la diferencia de 0,64 puntos frente al valor vigente no está explicada, porque el 99,19 % nunca fue una medición. Desde la corrida CAP-3-BIS se cita **99,83 %**, con identificador de corrida y salida cruda archivada en el repositorio.

El ajuste no es cosmético y está medido por un segundo camino: basta excluir las órdenes de 2017 y 2018 (los años más golpeados por el borde del universo) para que el enlace suba de 91,01 % a **98,64 %**, y a **99,39 %** desde 2020. **La caída en años tempranos es un artefacto del borde del universo cargado, no una pérdida real de trazabilidad.**

66,97 % y 70,24 % llevan una salvedad menor: se calculan en la Celda 7 del cuaderno (variantes (d) y 7.3) y se imprimieron en la corrida 86a9f215712a; su salida cruda no está archivada aparte, aunque el número es trazable en código.

2.4.4 · Determinismo y validación externa

La cascada de texto evaluable (la medición central de §3.4.3) se ejecutó **cinco veces**, con identificadores de corrida distintos, en días distintos, y devolvió el mismo resultado al segundo decimal en las cinco: 51.451.528 líneas, 99,60 % no nula, 97,02 % no relleno, **81,87 % evaluable**.

Alcance y límites:

Prueba que **el pipeline no depende de estado oculto ni de orden de ejecución**. No prueba que el resultado «no fuera suerte»: no había ningún componente aleatorio que pudiera haber intervenido. La distinción importa porque afirmar lo segundo es lo que un examinador desarma en una pregunta, y afirmar lo primero se defiende solo.

Y antes de afirmar nada sobre los datos hay que demostrar que el pipeline capturó lo que dice haber capturado: que en la descarga no se perdió ni se duplicó nada. La comprobación se hace contra una cifra que ChileCompra publica oficialmente, y la vara elegida es el **número de órdenes de compra**, no el monto. La razón es deliberada: **contar documentos da el mismo resultado para cualquiera que lo cuente**, mientras que un monto cambia según se incluya o no el IVA, según el tipo de cambio del día y según si la cifra oficial suma cargos y descuentos. Una vara discutible no sirve para validar.

98,25 % [MEDIDO]. de las órdenes de compra que ChileCompra declara oficialmente para 2024 están en este pipeline. **1.996.187 capturadas de un total oficial de 2.031.670** (cifra publicada por ChileCompra el 9 de junio de 2025) **[FUENTE]**.

La reconciliación en pesos es más ruidosa y se declara como tal: la razón contra la cifra oficial es 0,7425 sobre el gasto saneado, y sube a **0,8836 al aplicar un factor de 1,19 por IVA**. El 12 % restante corresponde a monedas distintas del peso, órdenes anuladas, cargos y descuentos. **El factor 1,19 es una aproximación de primer orden: no descuenta bienes exentos ni los cargos y descuentos de línea**, cuyas columnas existen en los datos pero no se usaron.

2.5 · Consulta de Datos e Insights

Las cuatro preguntas de §1.2 se traducen en cuatro familias de consulta sobre las tablas transformadas. Esta sección dice **qué se le preguntó a los datos y con qué control**; los resultados están en §3.4.

De la pregunta de investigación a la consulta, con su control predeclarado

#	Consulta	Control fijado antes de correr
P1	Join OC↔licitación por clave, y comparación del código ONU a 8, 6, 4 y 2 dígitos	Baseline nulo permutado : se permutan los códigos al azar y se repite la medición. Sin él, una tasa de coincidencia alta puede ser puro efecto de frecuencia del catálogo
P2	Serie anual del indicador de evaluabilidad, entre 2017 y 2026, completa y restringida a organismos presentes en ambos años	Semi-join a organismo y a unidad de compra (descarte de composición) + placebo sobre pares de años sin intervención normativa + intervalo de confianza de la diferencia de proporciones
P4	Cascada de evaluabilidad del texto libre, y tres tamices de coherencia código↔texto sobre muestra estratificada con patrón oro humano	Umbral de convergencia entre métodos de ± 10 pp fijado antes de correr, y κ de Cohen para medir si coinciden en los mismos casos y no solo en la tasa
P3	Dispersión de precio (p75/p25) por código × unidad × año, y apertura manual de 30 fichas públicas	Mínimo de cinco organismos por celda, precio mínimo de 100 pesos, unidades no comparables excluidas; y para los 30 casos, cuotas de grupo predeclaradas y cruce obligatorio contra el catálogo

Nota metodológica:

Las cuatro preguntas miden si el código *calza*. Ninguna mide si la discordancia **tiene consecuencias observables**, y sin eso, un examinador puede decir con razón que todo el trabajo describe un problema de archivo. Se agregó por eso un **estudio de asociación**: si el código ONU de la licitación no comparte ni el segmento de 2 dígitos con el de su orden de compra, ¿cambia la probabilidad de que la

licitación haya recibido un solo oferente? Con **estratificación por sector × año × tramo de monto (Mantel-Haenszel)**, un placebo, y cuatro criterios de aceptación fijados antes de correr. Resultado en §3.4.1.

3. Resultados

3.1 · Scripts y Código de Ingesta de Datos

La ingesta se sostiene en tres scripts. El resolutor de alias es el que evita más errores silenciosos.

Scripts de la Etapa 1, en el repositorio del proyecto

Archivo	Qué hace
local/esquema_comun.py	Diccionario de alias por dataset y por año, y el resolutor de columnas. Es el archivo que hace que diez años se puedan unir sin perder columnas en silencio
notebooks/paso0_reconciliacion_de_cortes.py	Compara el corte congelado contra una re-descarga independiente, archivo por archivo y mes por mes
notebooks/paso0e_inventario_particiones.py	Inventario físico de las particiones Parquet: filas por partición, duplicados exactos, líneas por documento
notebooks/exportar_esquema_v1.py	Exporta el esquema resuelto para que un tercero pueda verificar qué columna real se usó para cada campo lógico

local/esquema_comun.py, el resolutor de alias. Existe porque los encabezados del portal cambian entre años y entre datasets.

```
# Dado el listado de columnas reales de un archivo y una lista de alias
# candidatos, devuelve el nombre REAL de columna que calza
# (case-insensitive, espacios colapsados) o None si ninguno calzo.
def resolver_alias(columnas_reales, aliases):
    import re
    norm_map = {}
    for c in columnas_reales:
        key = re.sub(r"\s+", " ", str(c).strip()).lower()
        norm_map[key] = c
    for alias in aliases:
        key = re.sub(r"\s+", " ", alias.strip()).lower()
        if key in norm_map:
            return norm_map[key]
    return None
```

Función crítica, no un detalle de plomería: devuelve None cuando ningún alias calza, en vez de inventar una columna vacía. Un union de diez años que rellena con nulos la columna que no encontró produce un pipeline que corre sin error y una cifra que no significa nada. **La misma función se usa en el script de gates G1 a G6,**

para que los dos resuelvan los alias de forma idéntica y un gate no pueda aprobar un archivo que el pipeline luego lee distinto.

3.2 · Scripts y Código de Transformación de Datos

La Etapa 2 es un cuaderno de **70 celdas** (notebooks/etapa2_ANEXO_PROFESOR_v19.py, el que se entrega). De ahí salen dos fragmentos que concentran lo esencial del trabajo: la **definición operativa de «texto circular»**, que es el hallazgo principal, y la **permutación del baseline nulo**, que es lo que hace interpretable la Pregunta 1.

etapa2_ANEXO_PROFESOR_v19.py, CAP-10 (G7): cascada de texto evaluable. Define el criterio de «circular».

```
_txt = F.coalesce(_t_c, _t_p) # el comprador manda; el proveedor complementa
_gen = g7_norm(F.col(c_gen)) # nombre generico del producto, del propio registro

_f_nonull = _txt.isNotNull()
_f_largo = F.length(_txt) >= F.lit(MIN_CHARS_G7)
_f_nomule = ~_txt.rlike(_rx_mule) # 33 patrones de muletilla, anclados
_f_nocirc = (_gen.isNull()
             | (~(_txt == _gen) & ~_gen.contains(_txt) & ~_txt.contains(_gen)))

_f_eval = _f_nonull & _f_largo & _f_nomule & _f_nocirc
```

El criterio central de esta sección es `_f_nocirc`. Una línea es circular (y por tanto no auditable) si su texto libre es igual al nombre genérico del producto, o si uno contiene al otro. No es una heurística de similitud: es contención literal después de normalizar, y por eso el resultado es **determinista y reproducible al segundo decimal en cinco corridas**. Además, `_gen.isNull()` hace pasar el filtro: **si no hay nombre genérico contra el cual comparar, la línea se considera no circular**, ya que el criterio se inclina a favor del dato, no en contra.

celdas_capstone_v12.py, CAP-1: baseline nulo permutado de la Pregunta 1.

```
# Baseline nulo: permutacion DETERMINISTA dentro de (año × bucket)
w_a = W.partitionBy("anio","bucket").orderBy(F.xxhash64("k", F.lit(SEED_NULO)))
w_b = W.partitionBy("anio","bucket").orderBy(F.xxhash64("k", F.lit(SEED_NULO + 7)))

izq = par.withColumn("_i", F.row_number().over(w_a))
der = (par.select("anio","bucket","k", F.col("set8_oc").alias("set8_oc_x"))
      .withColumn("_i", F.row_number().over(w_b)).drop("k"))

par_perm = izq.drop("set8_oc").join(der, ["anio","bucket","_i"], "inner")

real = _metricas(par, "" ).withColumn("serie", F.lit("1_real"))
nulo = _metricas(par_perm, "_x").withColumn("serie", F.lit("2_nulo_permutado"))
```

Tres decisiones deliberadas en diez líneas. **La permutación es determinista**: se ordena por xxhash64 de la clave con dos semillas distintas, no por `rand()`, así que el baseline es el mismo en cada corrida y la cifra se puede reproducir. **Se permuta dentro de (año × bucket)**, no sobre todo el universo: si se permutara globalmente, el baseline mediría además la diferencia entre años y entre tamaños de licitación, y saldría artificialmente bajo. Y **la celda compara los n de las dos series y alerta si difieren**: si la permutación pierde filas, real y nulo están midiendo universos distintos y la brecha no vale nada.

Nota metodológica: otras transformaciones aplicadas, resumidas en una línea cada una. **Parseo numérico tolerante:** los montos vienen con coma decimal, punto de miles o notación científica según el año; el clasificador distingue siete formas y marca dos como *ambiguas* en vez de adivinar. **Normalización de modalidad:** LQ y H2 se agrupan en LP para el contraste grande/chico. **Clasificación del código ONU:** AUSENTE, CERO, VALIDO_8, OTRO_FORMATO, que es la que produce la tabla de malformados de §3.4.5. **Extracción de año y mecanismo desde el sufijo del código** (2981-793-SE17 → año 2017, tipo SE), que es lo que permite medir el borde del universo. **Muestreo estratificado con pesos de Horvitz-Thompson:** 911 estratos sobre 41.696.043 líneas evaluables.

3.3 · Descripción y Muestra de los Datasets Transformados

La Etapa 2 produce nueve tablas exportadas a CSV, que son las que alimentan el informe y el dashboard. Todas están en el repositorio.

Datasets transformados, y qué representa una fila en cada uno

Tabla	Una fila es...	Qué contiene
cap1_real_vs_nulo	serie × universo × bucket	consistencia lic↔OC real contra baseline nulo permutado, a 2/4/8 dígitos
cap2_serie_onu_por_anio	año	indicador de evaluabilidad, serie completa y restringida, con su n y el número de organismos
cap9_cascada	peldaño	cascada de trazabilidad hasta el producto declarado, ponderada por gasto
v1_codigos_6d3	código × unidad × año	celdas con volumen real para la dispersión de precio
curva_maduracion	mes de archivo	completitud de FechaAdjudicacion y estado declarado, por antigüedad
cap11c_muestra_reponderada	línea muestreada	300 líneas con su estrato, sus pesos y el veredicto de los tamices
cap12_desacuerdos_top200	par (texto, código)	los 200 desacuerdos de mayor peso entre código declarado y código propuesto

Muestra real de la tabla central

cap2_serie_onu_por_anio.csv: las diez filas completas, tal como salen del archivo

Año	% completa	% restringida	líneas (restringida)	organismos
2017	97,1794	97,1829	6.586.452	N/D
2018	97,1494	97,1535	6.593.542	N/D
2019	96,9347	96,9425	6.193.214	N/D
2020	93,9347	93,9416	4.398.136	N/D

Año	% completa	% restringida	líneas (restringida)	organismos
2021	90,5220	90,5215	4.264.180	N/D
2022	86,7183	86,7187	4.727.548	N/D
2023	86,1451	86,1453	5.167.473	N/D
2024	85,2360	85,2348	5.343.649	1.086
2025	85,5154	85,5370	5.129.022	1.172
2026*	82,4166	82,3947	2.925.771	N/D

[MEDIDO] · 2026 parcial. **Este archivo es el que permite calcular el intervalo de confianza de §3.4.2**, porque trae el n de la serie restringida y no solo el porcentaje, una columna que hubo que agregar explícitamente a la celda de exportación cuando se descubrió que faltaba.

Salvedad: en cap11c_muestra_reponderada.csv, la columna _estrato tiene **300 valores distintos para 300 filas: un estrato por fila**. Cualquier cálculo de percentil «dentro del estrato» sobre ese export da 100 % para las 300 filas sin excepción: no discrimina nada. Se detectó porque un grupo de la muestra de 30 casos salía estructuralmente vacío, y se corrigió agrupando por rubro_n1. Es un defecto que no genera error y produce una tabla aparentemente válida.

3.4 · Visualización de Datos de los Resultados de Consulta

Las cuatro preguntas de investigación, cada una con su control predeclarado, su salvedad metodológica y su identificador de corrida.

3.4.1 · Pregunta 1: ¿sabe el Estado qué compra?

La pregunta se formula así: dada una orden de compra que se pudo enlazar con su licitación de origen, ¿el código de producto que declara la orden coincide con el que declaró la licitación? La respuesta tiene dos capas, y la segunda es la más relevante.

94,44 % [MEDIDO] de consistencia real a nivel de familia de producto (cuatro dígitos), contra un baseline nulo permutado de 1,38 %: una brecha de 93,06 puntos porcentuales sobre 190.232 casos comparables. Run_id 1314c4f6d481, reproducido exacto en 70680deaec66 y 628c163f82e7.

El baseline nulo es la pieza que hace interpretable la cifra. Una tasa de coincidencia del 94 % no dice nada por sí sola si no se sabe cuánto habría dado el azar: si el catálogo estuviera dominado por un puñado de códigos, dos documentos podrían coincidir por pura frecuencia. Permutando los códigos y repitiendo la medición se obtiene el 1,38 %. **La brecha es sustancial.**

Como prueba de robustez, la misma pregunta medida como cobertura ponderada sobre el universo enlazado da **76,79 % por línea y 97,04 % por peso gastado [MEDIDO]** (628c163f82e7). Las dos lecturas apuntan en la misma dirección: donde el dato existe, el dato es razonable.

Pero la comparación casi nunca es posible: este es el hallazgo central. De 964.171 licitaciones analizadas:

Composición del universo de licitaciones según su capa de producto declarada

Categoría	Licitaciones	%	Qué significa
Declara a lo más un código de producto	772.105	80,08 %	No hay conjunto que comparar
de ellas, patología testimonial : varias líneas, un solo código distinto	128.543	13,33 %	Declara producto de forma nominal, no informativa
Complemento, declara más de un código	192.066	19,92 %	El universo candidato a comparación
Universo informativo efectivo, donde se mide el 94,44 %	190.232	19,73 %	Ligeramente menor que el complemento

[MEDIDO] Los porcentajes 80,08 % y 13,33 % son derivaciones declaradas sobre los conteos impresos por la corrida: $(643.562 + 128.543) / 964.171$ y $128.543 / 964.171$ respectivamente.

Aclaración: pensemos en una licitación de material de oficina que no pasa por Convenio Marco. En la práctica compra productos distintos (papel, lápices, cola fría, cuadernos, corchetes) y sus bases pueden traer veinte líneas, una por cada ítem, cada una con su propio código ONU. Esa es la licitación tal como este informe la mediría si declarara su capa de producto correctamente.

Lo que este hallazgo dice es que, en el 80,08 % de las licitaciones, eso no ocurre: la licitación entera queda con un solo código de producto declarado, o ninguno, sin importar cuántos ítems distintos contenga. Y en un 13,33 % adicional sí hay varias líneas, pero todas repiten el mismo código, como si las veinte líneas del ejemplo quedaran todas etiquetadas con el código de «papel».

La orden de compra que se genera al adjudicar sí puede heredar el detalle línea por línea de la oferta ganadora, y por eso cuando la comparación es posible el 94,44 % coincide. El problema no es que el dato se pierda al pasar de licitación a orden: es que **la licitación misma, el documento que compromete el gasto, casi nunca lo declaró bien desde el principio.**

Diferencia declarada, no explicada: el complemento aritmético de las licitaciones que declaran a lo más un código es **192.066**, pero la comparación corre efectivamente sobre **190.232** casos. La diferencia son **1.834 licitaciones, un 0,19 % del universo**, y la causa más plausible es que no traigan código válido en ambos lados, pero **este informe no lo afirma, porque no está medido.** Se declara la brecha y se usa la cifra menor.

80,08 % [MEDIDO] de las licitaciones del Estado declaran **a lo más un código de producto**, sea cual sea el tamaño del contrato. **El hallazgo de la Pregunta 1 no es la tasa de coincidencia: es que solo el 19,73 % del universo permite hacerse la pregunta.**

¿Es un sesgo de las licitaciones grandes? Si la capa de producto vacía afectara sobre todo a los contratos grandes, la Pregunta 1 se estaría midiendo sobre una submuestra de compras chicas. Se probó explícitamente, con umbrales fijados antes de correr, y la hipótesis **no se sostuvo [MEDIDO]**: licitaciones grandes (LR, LQ, LP, H2) con cero o un código ONU, **87,0 %** ($n = 212.339$); chicas (LE, L1), **81,4 %** ($n = 994.252$). Brecha de 5,6 puntos, por debajo del umbral de 10 puntos predeclarado. El enlace por tamaño da 99,67 % contra 99,93 %, y por antigüedad del proceso 99,76 % contra 99,54 %. El veredicto predeclarado fue **«pérdida difusa»**: ni el tamaño ni la antigüedad separan. **Grandes y chicas declaran una capa de producto igualmente pobre.**

Salvedad: una precisiones sobre el párrafo anterior.

1. $212.339 + 994.252 = 1.206.591$, que no es 964.171. Los dos universos son distintos: este contraste cuenta sobre el universo de líneas con modalidad resoluble, y el 80,08 % cuenta licitaciones. **No son comparables entre sí y no se suman.**


Con un matiz que apareció al mirar la tabla completa: los procedimientos de **Trato Directo con resolución** (R1, R2, R4) enlazan bastante peor (89,42 %, 77,99 % y 55,00 %) pero son volúmenes chicos y quedan fuera del contraste grande/chico por construcción. Es un pendiente declarado de baja prioridad, no una corrección al resultado.

¿Importa la discordancia? Asociación con el número de oferentes

Todo lo anterior mide si el código declarado calza. Queda una pregunta distinta: **¿la discordancia tiene alguna consecuencia observable?**

OR $\approx$ 2,0 [MEDIDO] OR de Mantel-Haenszel = 1,9989, IC 95 % [1,9159, 2,0856], sobre 128 estratos de sector $\times$ año $\times$ tramo de monto (214 estratos descartados por tener menos de 30 licitaciones o no tener variación). Placebo (paridad de hash de la clave de licitación, sin relación posible con el desenlace) limpio: OR_MH = 0,9962, IC 95 % [0,9864, 1,0061], dentro del umbral predeclarado. **Los 4 criterios en OK, asociación sostenida.** Run_id bc06eb233fc5.

Dentro del mismo sector, año y tramo de monto, las licitaciones totalmente discordantes (apenas el **1,00 %** del universo pareado) tienen aproximadamente el doble de probabilidad de haber tenido un solo oferente que las que declaran el mismo código a 8 dígitos en ambos documentos. La tasa de oferente único sube monótonamente con la discordancia: **20,42 %** cuando el código es idéntico, entre **29,26 % y 30,04 %** en los niveles intermedios, **35,28 %** cuando no comparten ni el segmento de 2 dígitos.



Tasa de licitaciones con un solo oferente, por nivel de discordancia del código ONU

Tasa de licitaciones con un solo oferente, por nivel de discordancia del código ONU [MEDIDO]

- Código concordante

- Niveles intermedios
- Discordante total, 1,00 % del universo pareado

Cómo se lee esta cifra: «OR» (razón de probabilidades) dice cuántas veces más probable es que ocurra algo en un grupo que en otro. **OR = 2** significa «el doble de probable»; **OR = 1** significa «exactamente igual, no hay relación».

«De Mantel-Haenszel» significa que la comparación no se hizo mezclando todo el país en una bolsa. Se hizo por separado dentro de cada combinación de sector × año × tramo de monto (128 combinaciones) y recién después se juntaron los resultados. Eso evita la trampa clásica de comparar compras de salud con obras públicas y atribuirle al código lo que en realidad era el rubro.

El **«IC 95 %»** es el rango dentro del cual está el valor verdadero con 95 % de confianza. Aquí es [1,92, 2,09]: angosto, y no toca el 1. Si tocara el 1, no se podría descartar que no haya ninguna relación.

El **placebo** es la prueba de que el método no inventa relaciones donde no las hay: se repitió el cálculo completo usando una variable sin ninguna relación posible con el resultado, y dio OR = 0,9962, es decir, nada, que es lo que tenía que dar. Si el placebo hubiera salido alto, el resultado principal no valdría.

Alcance y límites: es una asociación, no un efecto causal. Con diseño transversal, la causalidad inversa es igual de plausible: una licitación con un solo oferente puede recibir menos escrutinio de codificación, no al revés. Este resultado cubre solo licitaciones **adjudicadas que generaron orden de compra**; las desiertas o canceladas quedan fuera por construcción y no están medidas. Y el denominador excluye, sin que se pueda descartar sesgo, las licitaciones adjudicadas después de la fecha de descarga. **No hay ranking de organismos ni de proveedores en este resultado, ni lo habrá si se cita en la presentación.**

[MEDIDO] El mismo estudio pareó **962.336** licitaciones contra las 964.171 de este capítulo: una brecha de 1.835, del mismo orden que la de 1.834 declarada arriba, con dos joins distintos. Es un indicio de que la causa es estructural, no una confirmación de causa común.

3.4.2 · Pregunta 2: ¿cambió cuando la ley lo exigió?

El 12 de diciembre de 2024 entró en vigencia la obligación legal de clasificar y codificar. 2024 es el último año completo sin ella; 2025, el primero con ella. La comparación es directa y el resultado es que no pasó nada.

+0,28 pp [MEDIDO] es todo lo que se mueve el indicador de evaluabilidad entre el último año sin obligación legal de codificar y el primer año completo con ella. **85,24 % (2024) → 85,52 % (2025).**

El confundidor, y por qué el resultado sobrevive. Hay un problema serio con esa comparación, y este trabajo lo encontró antes de publicarla. **El mismo 12 de diciembre de 2024 en que entra en vigencia el artículo 20 bis, ingresa al sistema una ampliación grande del universo de entidades compradoras [FUENTE]** (Congreso, Poder Judicial, Ministerio Público, Contraloría, entre otras). Los dos eventos están confundidos por construcción: cualquier movimiento del indicador podría ser cambio de conducta o cambio de censo. Se probó a tres niveles, todos con criterio fijado antes de correr:

Robustez del +0,28 pp frente al cambio de población

Prueba	2024	2025	Δ	Lectura
Sin restringir (serie completa)	85,24	85,52	+0,28	Cifra base

Prueba	2024	2025	Δ	Lectura
	%	%	pp	
Restringido a los 1.079 organismos presentes en ambos años	85,23 %	85,54 %	+0,30 pp	La entrada de organismos no lo explica
A nivel de unidad de compra (granularidad más fina)	85,25 %	85,67 %	+0,42 pp	Consistente en signo y magnitud

[MEDIDO] 628c163f82e7 · 26 de agosto de 2026 (sin salida cruda archivada en el paquete; ver la salvedad de §3.4.1).

Y se corrió además un **placebo predeclarado**: la misma prueba de semi-join sobre pares de años sin intervención normativa. 2022→2023 dio -0,59 pp y 2023→2024 dio -0,88 pp, ambos de signo contrario al +0,30 pp de 2024→2025. **El movimiento observado no es el ruido normal de año a año**, y tampoco es una mejora de tamaño relevante.

El +0,30 pp, con intervalo de confianza

Un delta sobre cinco millones de filas por lado puede ser «estadísticamente significativo» y, a la vez, no significar nada sustantivo. Se calculó el intervalo de confianza del 95 % de esta diferencia de proporciones (método de Newcombe: diferencia de dos intervalos de Wilson score) sobre el semi-join restringido a los 1.079 organismos comunes: $n_{2024} = 5.343.649$, $n_{2025} = 5.129.022$.


[+0,26, +0,35] pp [MEDIDO] es el intervalo de confianza del 95 % del Δ de **+0,3022 pp** (2024→2025, serie restringida). **Excluye 0, es estadísticamente significativo, pero queda muy por debajo del umbral sustantivo de 1 pp fijado antes de calcularlo.** Derivado: método de Newcombe sobre el n de la columna `líneas_restringida`. Reimplementado desde cero en la auditoría del 6 de septiembre: reproduce exacto (+0,3022 pp; [+0,2594, +0,3450]).

Lectura: con un n del orden de millones, hasta una diferencia de unas pocas décimas de punto porcentual cruza el umbral de significancia estadística. Que el intervalo no toque el cero no convierte el movimiento en una mejora relevante del indicador. **Significativo y sustantivamente nulo** es la frase que resume el capítulo.

Una analogía para no confundir las dos cosas: si se pesa a un millón de personas antes y después de un cambio de dieta y en promedio bajaron doce gramos, la medición puede ser exactísima (y el intervalo de confianza, angostísimo) y aun así *el resultado no significa nada*. «Estadísticamente significativo» quiere decir «el número no es ruido de medición»; no quiere decir «el número es importante». Eso es exactamente lo que pasó con el artículo 20 bis en su primer año.

La serie completa cuenta una historia más fuerte

Mirar solo 2024 contra 2025 hace perder el hallazgo mayor. La serie de diez años muestra que la caída ocurrió antes, fue grande, y ya se había detenido cuando la norma entró en vigencia.



Indicador de evaluabilidad del código ONU, de 2017 a 2026

Indicador de evaluabilidad del código ONU, de 2017 a 2026 [MEDIDO]

- Indicador de evaluabilidad, serie sin restringir
- Entrada en vigencia del artículo 20 bis

Serie completa, el semi-join no separa las dos series en ningún año

Año	2017	2018	2019	2020	2021	2022	2023	2024	2025	2026*
Completa	97,18	97,15	96,93	93,93	90,52	86,72	86,15	85,24	85,52	82,42
Restringida	97,18	97,15	96,94	93,94	90,52	86,72	86,15	85,23	85,54	82,39

Tres lecturas que la comparación de 2024 a 2025 por sí sola no permite:

- **La forma es un quiebre, no una tendencia.** Meseta entre 2017 y 2019 (−0,24 pp en dos años), **caída de 10,22 puntos entre 2019 y 2022**, meseta entre 2023 y 2025 (±0,5 pp), y 2026 abajo otra vez. El +0,30 pp del que cuelga la Pregunta 2 es ruido sobre una caída de diez puntos que ocurrió tres años antes de la ley.
- **El semi-join no discrimina, y decirlo es más honesto.** Las series completa y restringida **no se separan más de 0,03 pp en ninguno de los diez años** (el máximo es 0,0219 pp, en 2026). Sirve como descarte de composición (el delta no viene de la entrada y salida de organismos) pero no como control, porque no hay nada que controlar si las dos series son la misma.
- **2026 no es comparable** y se dibuja marcado como parcial, por la razón que se explica en §3.4.5.

Aclaración: la comparación entre el **7,92 %** de organismos entrantes medido por el proyecto (86 de 1.086, definición anual) y el **≈35 %** que ChileCompra proyectó públicamente no es válida: el **≈35 %** mide *entidades obligadas a entrar [FUENTE]*, no entidades que efectivamente transaron. Son poblaciones distintas y no se contrastan entre sí.

La contraparte correcta, y la medición contra ella: ChileCompra declara que **217 organismos efectivamente transaron** entre el 12 de diciembre de 2024 y abril de 2025 [FUENTE]. Medido con la ventana exacta que declara esa fuente, el proyecto cuenta **56 organismos** cuya primera orden de compra cae dentro de ella [MEDIDO] (run_id 33251704e7f2). La brecha relativa es del **74,2 %** y **supera el umbral predeclarado de ± 25 %: NO CONVERGE.**

La medición existe; la causa de la brecha no está determinada y este informe no la afirma. Una lectura obligatoria que la propia celda imprime: «organismo nuevo» significa *sin ninguna OC previa en el corte cargado*, que empieza en 2017: un organismo que compró antes de 2017 y volvió en 2025 aparece como entrante sin serlo. **Esto no toca el resultado de la Pregunta 2**, que se apoya en el semi-join y el placebo, no en el conteo de entrantes.

La frase del capítulo: «Entre el último año sin obligación legal de codificar y el primer año completo con ella, el indicador se mueve 0,28 puntos porcentuales. Un año es poco para una norma con reglamento nuevo, y la ley exige *codificar*, no que la especificación de texto sea informativa. Esto no es evidencia de incumplimiento: **es evidencia de que la obligación, tal como está escrita, no produce verificabilidad.**»

3.4.3 · Pregunta 4, el hallazgo principal: el texto que debería verificar el código es una copia del código

Un código de producto se puede auditar de una sola manera con datos abiertos: comparándolo contra la descripción en texto libre de la misma línea. Si el texto dice «resma de papel carta 500 hojas» y el código dice «papel para fax», hay algo que revisar. Este capítulo mide cuántas líneas permiten esa comprobación, y descubre que la proporción cae por una razón identificable.

Cascada de evaluabilidad sobre 51.451.528 líneas de orden de compra

Filtro acumulado	Líneas	% del universo
Universo total	51.451.528	100,00 %
+ texto no nulo	51.247.066	99,60 %
+ no es muletilla ni texto de menos de 12 caracteres	49.917.404	97,02 %
+ no es circular = EVALUABLE	42.122.558	81,87 %
NO EVALUABLE, el complemento, que es el hallazgo	9.328.970	18,13 %

[MEDIDO] fb7c3b125bf7 · reproducido en cinco corridas independientes.

CASCADA DE EVALUABILIDAD, 51.451.528 LÍNEAS DE ORDEN DE COMPRA · MEDIDO

Universo total – 100,00 % · 51.451.528

+ texto no nulo – 99,60 % · 51.247.066

+ no muletilla ni texto <12 caracteres – 97,02 % · 49.917.404

= EVALUABLE, no circular – 81,87 % · 42.122.558

El último peldaño — 15,15 pp, 7.794.846 líneas — es exactamente el texto circular: el 83,56 % de todo lo no evaluable.

Cascada de evaluabilidad, 51.451.528 líneas de orden de compra


Cascada de evaluabilidad, 51.451.528 líneas de orden de compra [MEDIDO]

El último peldaño (15,15 pp, 7.794.846 líneas) es exactamente el texto circular: el 83,56 % de todo lo no evaluable.

«Circular» tiene aquí una definición operativa precisa, y es una definición de este proyecto, no oficial (el código está en §3.2): el texto de la especificación es una copia del nombre genérico del producto que ya trae el propio registro, o uno contiene al otro. Cuando eso ocurre, el texto no aporta evidencia independiente del código: repite el código con otras palabras.

83,56 % [MEDIDO] de las 9.328.970 líneas no evaluables lo son por **texto circular**, no por falta de texto. Solo el 2,19 % no trae texto y el 14,25 % trae texto muy corto o una muletilla. **El problema no es que el Estado no escriba: es que escribe algo que no verifica nada.** $7.794.846 / 9.328.970 = 83,5553 \%$.

El problema se concentra en un mecanismo: Convenio Marco. Desagregada por mecanismo de compra, la circularidad deja de ser una tendencia difusa y se vuelve un fenómeno de un solo mecanismo.



Fracción de líneas con texto circular, por mecanismo de compra, de 2017 a 2026

Fracción de líneas con texto circular, por mecanismo de compra, de 2017 a 2026 [MEDIDO]

- Convenio Marco
- SE · sin emisión automática (OC ordinaria)
- Compra Ágil
- **Convenio Marco: rampa de 2019 a 2023 y meseta después.** 6,65 % → 15,71 % → 40,17 % → 88,96 % → 99,80 %, y de ahí no se mueve (99,86 % en 2026). Esa forma (escalonada en tres años y luego pegada al techo) **no tiene la firma de treinta mil compradores cambiando de hábito: tiene la firma de una decisión de formato de la plataforma.**
- **La orden de compra ordinaria (SE) mejora, monótonamente:** de 7,97 % en 2017 a 4,50 % en 2026, una caída de 3,47 puntos en nueve años. En el tramo de 2019 a 2026 la mejora es de 7,68 % a 4,50 %, es decir 3,18 puntos. **Los dos periodos no deben confundirse entre sí.**
- **Compra Ágil nace en 2020** (7,91 %), se estabiliza entre 7,9 % y 10,6 % y baja al final. No es el problema.

Aclaración: el diccionario de datos oficial de órdenes de compra de ChileCompra documenta que SE significa «sin emisión automática» y CM «Convenio Marco» [FUENTE]. SE **no es un procedimiento especial: es la orden de compra ordinaria**, la que se emite contra un proceso y cuya especificación de texto escribe una persona. La evidencia interna lo corrobora: SE es el **44,5 %** de todas las líneas y el único tipo con enlace real a licitación (**73,49 %** trae código de licitación, contra **0,0 %** de Convenio Marco). Una subasta electrónica no puede ser casi la mitad del volumen nacional; la OC ordinaria sí.

Con los nombres correctos, el hallazgo es más preciso: no es «un mecanismo empeora y otro mejora», sino que **donde el texto lo escribe una persona, la circularidad cae; donde lo genera el catálogo de la plataforma, sube hasta el 99,86 %**. La etiqueta de cada serie contiene el mecanismo causal del hallazgo. (TD, CT y CB no están documentados en el diccionario oficial: se usa el código tal cual.)

¿Es composición o es conducta?

La pregunta natural es si la circularidad agregada sube porque Convenio Marco empeoró o porque Convenio Marco pesa más. La respuesta es contraintuitiva: **Convenio Marco pesa menos que antes** (cae del 54,8 % del volumen en 2019 al 17,6 % en 2026) **y aun así aporta la mayor parte del deterioro.**

Contribución de Convenio Marco a la circularidad total (subtotal CM+SE+AG)

Año	2017	2019	2021	2022	2023	2024	2025	2026
CM aporta	9,28	3,64	9,76	13,34	13,87	14,79	14,49	17,58 pp
Total de los tres mecanismos	12,87	6,76	n/d	n/d	n/d	n/d	n/d	22,42 pp

78,4 % [MEDIDO] de toda la circularidad de 2026 la explica Convenio Marco, **con el 17,6 % del volumen de líneas.** Derivación declarada sobre la tabla Q1.A redondeada a un decimal; no es salida directa de la corrida.

Nota metodológica: la herramienta estándar para separar composición de conducta es una **descomposición shift-share**. El pipeline la calcula, pero este informe no la cita: su término de interacción es **-27,63 puntos sobre un alza total de +9,55**, es decir casi tres veces el efecto que pretende descomponer. Cuando eso ocurre, la descomposición **no está identificada** (Convenio Marco cambió su tasa y su peso al mismo tiempo y en direcciones opuestas) y sus porcentajes son artefactos aritméticos. Afirmar que «el 462 % del alza es conducta» es indefendible.

Analogía: alguien baja de peso cambiando la dieta y empezando a hacer ejercicio, las dos cosas al mismo tiempo. Parte del efecto es «dieta y ejercicio juntos», y no hay forma limpia de repartir ese pedazo entre uno y otro. Cuando ese pedazo mezclado es *más grande que la baja total*, la cuenta no puede separar las causas. Por eso se miden en su lugar dos escenarios contrafactuales, recalculables a mano.

En su lugar, dos contrafactuales que cualquiera puede recalcular a mano [MEDIDO] · derivado

Escenario	Circularidad 2026
Observado	22,42 pp
Si la mezcla de mecanismos siguiera siendo la de 2017 (tasas reales de 2026)	≈ 57 pp
Si las tasas siguieran siendo las de 2017 (mezcla real de 2026)	≈ 6 pp

Síntesis: «Si la composición del mercado no hubiera cambiado, la circularidad de 2026 sería 57 puntos, no 22. Si solo hubiera cambiado la composición y ninguna tasa, sería 6 puntos, no 22. **El deterioro está en las tasas, y la caída de Convenio Marco como fracción del volumen lo estuvo tapando.**»

[POR VERIFICAR] Los valores exactos son 56,94 y 5,94, pero se citan redondeados: son derivaciones sobre una tabla ya redondeada a un decimal y el segundo decimal no es estable.

El mecanismo, visto desde el otro lado

Hay una segunda medición, con un método completamente distinto, que apunta al mismo lugar. Al exportar los 200 desacuerdos de mayor peso entre el código declarado y el que un modelo de similitud de texto propone, **188 de los 200 (94,0 %, y el 96,72 % de las líneas del export) abren con un identificador interno del catálogo de Convenio Marco** del tipo «1224202 promocionales 1250207» [MEDIDO], replicado en dos implementaciones independientes.

Los dos hallazgos son el mismo hecho visto por dos lados: **el catálogo de Convenio Marco genera la especificación de texto automáticamente a partir del nombre del propio producto de catálogo**. Por eso el texto es circular, y por eso arruina cualquier análisis léxico: un identificador numérico interno es ruido puro para un modelo de texto.

Alcance y límites: que el texto sea circular **no prueba** que se haya comprado otra cosa, ni que alguien haya codificado mal, ni que un organismo incumpla. Prueba que **la línea no es auditable con lo publicado**. Esa es toda la afirmación, y alcanza. El hallazgo es sobre **la plataforma**, no sobre los compradores: ninguno escribe ese texto, lo escribe el sistema. La conclusión defendible es: «*el mecanismo que más creció en trazabilidad formal es el que menos evidencia verificable publica*».

Dos tamices archivados, y un tercero sin respaldo: la corrección más importante del 6 de septiembre

Sobre una muestra estratificada de **300 líneas** con patrón oro humano se corrieron tres tamices de coherencia código↔texto de arquitecturas distintas. No son tres algoritmos independientes que dicen lo mismo: la tabla siguiente muestra por qué.

Tamices de coherencia sobre la misma muestra de 300 líneas

Método	Acierta	Estado del respaldo
Léxico, TF-IDF sobre n-gramas de caracteres, crudo	21,00 %	[MEDIDO] salida cruda archivada
Semántico de respaldo, LSA, 150 componentes sobre TF-IDF	10,67 %	[MEDIDO] salida cruda archivada. Su propio veredicto impreso es «DIVERGENTE» ($\Delta -10,33$ pp contra el léxico, fuera del umbral ± 10 pp)
Semántico real, transformer multilingüe paraphrase-multilingual-MiniLM-L12-v2	21,33 %	[SIN SALIDA ARCHIVADA] corrió fuera de este entorno el 26 de agosto, sin run_id y sin CSV por fila

Alcance y límites: el 21,33 % del transformer no tiene un solo byte de salida en el paquete de traspaso: corrió fuera del entorno del proyecto y el archivo por fila no se localizó. Además, el único tamiz semántico cuya salida sí está archivada (resultados/cap11b_tamiz_semantico_salida.txt) registra en su primera línea que sentence-transformers no estaba disponible (*ProxyError: 403 Forbidden*) y que cayó a LSA, con veredicto impreso **DIVERGENTE**.

Por lo tanto: la convergencia entre el léxico y el transformer se cita **declarando que el segundo no tiene respaldo archivado**, y se lee como **consistencia de tasa, no de caso** (dos métodos pueden marcar la misma proporción de líneas y marcar líneas distintas, ver la κ más abajo, que lo demuestra sobre esta misma muestra).

El hallazgo de fondo no depende de esa fila: lo sostiene el tamiz léxico, que sí está archivado y reproducido. **La mayoría de las líneas de orden de compra no calza ni siquiera a nivel de hoja del catálogo con el código que declara.** Esa afirmación se mantiene con el 21,00 % solo.

Los casos de mayor discrepancia son elocuentes y no requieren estadística para entenderse: «**corchetes n 6**» declarado como *lavaplatos de uso comercial*; «**queque nutra bien**» como *servicios de distribución de alimentos*; «**10 planchas zinc acanalada**» como *calamina*.

Cómo se lee esta cifra: la muestra de 300 se extrajo con un diseño que favorece a los estratos grandes, y por eso se reponderó con pesos de Horvitz-Thompson. Reponderada, la coincidencia a nivel de hoja sube de 7,67 % a **11,05 % [IC 95 %: 3,60, 21,21]**. El intervalo es ancho porque 300 líneas reponderadas valen estadísticamente como **49,18 observaciones independientes** (n efectivo de Kish sobre el ponderador de líneas).

El n efectivo depende del ponderador usado. Con el ponderador de líneas da **49,18**; con el ponderador de pesos da **5,82**. Para cualquier cifra en pesos de esta muestra el n efectivo real es 5,8, no 49,2 — un factor 8,5× de subestimación de la imprecisión si se usa el valor equivocado. Ninguna cifra en pesos de esta muestra se cita sin declarar este n.

Qué quiere decir «300 líneas valen como 49». La muestra se armó a propósito favoreciendo a los grupos más grandes, y al corregir ese sesgo unos pocos grupos enormes terminan concentrando casi todo el peso. En la práctica, muchas de las 300 líneas están «diciendo lo mismo»: la información estadística que aportan entre todas es la de unas 49 líneas verdaderamente independientes. Por eso el intervalo va de 3,60 % a 21,21 % en vez de ser un número fino, y por eso el n efectivo se declara siempre al lado de la cifra.

Dos métodos coinciden en el diagnóstico y casi nunca en el remedio

La tabla anterior compara *tasas*. Queda una pregunta más dura: cuando dos métodos corren sobre las mismas 300 líneas, **¿marcan las mismas líneas, o solo la misma proporción de líneas?** Se cruzó, caso a caso, el tamiz léxico contra el semántico de respaldo (LSA), los dos que sí tienen salida archivada.

$\kappa = 0,25$ [MEDIDO] κ de Cohen = 0,2521 [IC 95 %: 0,0846, 0,4196], concordancia **débil** (escala de Landis-Koch). El acuerdo observado desnudo es 79,67 % y el esperado por azar 72,81 %: casi todo el acuerdo es «ambos dicen que no». Los dos métodos coinciden en que el código declarado no calza en **222 de 300** líneas, pero **proponen el mismo código de reemplazo en solo el 5,00 %** (15 de 300). McNemar exacto sobre los 61 pares discordantes (46 solo-léxico, 15 solo-LSA): **$p = 0,000088$** , la discordancia tiene dirección, no es ruido simétrico. Local, sin Spark, sobre `cap11b_tamiz_resultado.csv` y su par semántico; κ ponderado cuadrático (5 niveles) = 0,2999.

Cómo se lee esta cifra: cuando dos métodos revisan las mismas líneas no basta con contar cuántas veces coinciden: hay que descontar las veces que coincidirían *de puro azar*. La **κ (kappa) de Cohen** hace exactamente eso: mide el acuerdo que sobra una vez descontada la casualidad, en una escala donde 1 es acuerdo perfecto y 0 es «coinciden lo mismo que si tiraran una moneda».

Aquí da **0,25**, que en la escala habitual se llama acuerdo **débil**. Los dos métodos coinciden el 79,67 % de las veces, pero de puro azar ya coincidirían el 72,81 %, porque casi todo el acuerdo consiste en que ninguno de los dos sabe cuál sería el código correcto. Ponerse de acuerdo en «no sé» no es ponerse de acuerdo.

La conclusión del capítulo es: **coinciden en el diagnóstico y casi nunca en el remedio.**

El diagnóstico es robusto al método; el remedio no lo es. Es la segunda vez que aparece este patrón en el trabajo (la tercera está en §3.4.4, con 30 casos abiertos a mano). **Tres fuentes independientes coinciden en que el pipeline puede marcar, no puede corregir**, que es exactamente la doctrina de este informe: alertas, no determinaciones.

Salvedad: es la concordancia **léxico ↔ LSA**, y LSA es el método cuyo propio veredicto dice «DIVERGENTE». El par que de verdad importaría, **léxico ↔ transformer**, no se pudo calcular: su corrida ocurrió fuera de este entorno y el archivo por fila no se localizó. **Se retiró del alcance el 3 de septiembre** como decisión declarada, no como omisión: reconstruirlo exigía re-correr el modelo sobre las mismas 300 líneas a seis días de la defensa. Y esta medición **tampoco cierra** la divergencia entre los dos algoritmos sobre los 200.000 pares (§4.2): es otra base y otra comparación.

3.4.4 · Pregunta 3, cuánto cuesta no saberlo, y los 30 casos abiertos a mano

El tamaño del objeto, gasto de la década, solo líneas en pesos chilenos [MEDIDO]

Concepto	CLP
Gasto crudo (suma de precio neto × cantidad)	126.889.600.153.921
Gasto saneado , tras excluir 1.331 líneas con firma de error	89.447.529.345.114
De ese gasto, trazable hasta el producto declarado	56,46 %

[MEDIDO] 1314c4f6d481 · corrida del 21 de agosto de 2026 · el filtro de saneamiento y su daño colateral están en §2.4.2.

Aclaración: Una sola línea de orden de compra registra **36.838.793.833.009 pesos**, el **29 % de todo lo transado en la década**, con el precio unitario idéntico a la cantidad ($6.069.497 \times 6.069.497$ = ese monto, exacto). La sospecha natural es que sea un defecto del procesamiento. No lo es: el campo `totalLineaNeto`, que trae el dato *publicado*, suma **126.925.942.772.073** contra los 126.889.600.153.921 que calcula el pipeline: una diferencia de **+36.342.618.152**, es decir **+0,0286 %**.

El signo de la diferencia indica que va en la dirección correcta: si el campo *publicado* no contuviera la línea de 36,8 billones, la diferencia sería de *menos* 36,8 billones, y es de *más* 36 mil millones. **El propio Mercado Público publica ese monto**. Es un hallazgo de calidad de datos, no una nota metodológica.

Limitación declarada: Antes de citar la cifra correspondía abrir la ficha pública de esa orden de compra en `mercadopublico.cl` y confirmar a mano que dice lo mismo. No se logró, por dos razones que quedan documentadas: (1) se verificó que **no existe un esquema de URL armable desde el código de la orden** (la ficha de detalle usa un parámetro `qs` cifrado y el buscador no acepta el código como parámetro directo); y (2) con un `qs` válido en mano, esa ficha específica devolvió **error de servidor tres días seguidos** mientras otras fichas sí abrían. La cifra se cita porque la sostiene la prueba independiente del párrafo anterior; la verificación manual queda declarada como no lograda, no como pendiente sin intentar.

La concentración, sobre 45.873.806 líneas en pesos con código ONU válido, ya saneadas

Ranking por gasto	% de las líneas	% del gasto
-------------------	-----------------	-------------

Ranking por gasto	% de las líneas	% del gasto
Top 10 códigos	1,26 %	28,35 %
Top 50	8,51 %	47,06 %
Top 100	15,55 %	56,40 %
Top 300	33,24 %	72,49 %



Concentración del gasto por código de producto, % de líneas vs. % del gasto saneado

Concentración del gasto por código de producto, % de líneas vs. % del gasto saneado [MEDIDO]

- % de las líneas
- % del gasto saneado

Hallazgo central: «El Estado usa 17.117 códigos distintos de los 18.881 del catálogo, y aun así **tres de cada cuatro pesos pasan por trescientos.**» Las dos cosas son verdad y juntas dicen más que cualquiera sola: el catálogo no está subutilizado, pero el dinero no se reparte como el catálogo.

Esta cifra corrige dos lecturas anteriores del propio proyecto: la primera midió la concentración por número de líneas (la vara equivocada) y concluyó que estaba refutada; la segunda dio 49,16 % para el top 10 porque incluía el código del outlier. **La cifra buena es 28,35 %**, sobre el universo saneado. (Un documento intermedio del proyecto, que está en el repositorio, cita 27,09 % como cifra saneada: fue reemplazado por el documento de cierre de las cifras en pesos, y 28,35 % es el valor final.)

La dispersión de precio, y por qué sola no se puede citar

La Pregunta 3 original (cuánto cuesta no saber qué se compra) se responde midiendo cuánto varía el precio unitario del mismo producto entre organismos. Con las unidades no comparables excluidas, precio mínimo de

100 pesos y al menos cinco organismos por celda, los ratios entre percentil 75 y percentil 25 quedan en un rango de **36 a 268**. Una celda con volumen real: código 41116004 · UNIDAD · 2022, con **n = 17.351 líneas y 163 organismos**, tiene p25 de 2.100 pesos, mediana de 53.900 y p75 de 189.000: **ratio 90,0**.

Celdas con volumen real, código × unidad × año [MEDIDO]

Celda	n	Organismos	p25	p50	p75	Ratio
41116004 · UNIDAD · 2022	17.351	163	2.100	53.900	189.000	90,0
85122201 · UNIDAD · 2024	30.070	395	n/d	n/d	n/d	44,9
41116105 · UNIDAD · 2024	12.537	164	n/d	n/d	n/d	47,9

Aclaración: Un percentil 25 de 2.100 pesos con una mediana de 53.900 no describe la dispersión de precio de un mismo bien: describe **un código ONU que agrupa cosas muy distintas**. Presentarlo como evidencia de sobreprecio sería la afirmación más frágil de todo el trabajo, y este informe no la hace.

Hasta el 5 de septiembre, ese freno era un argumento plausible, pero sin comprobar. Convertirlo en medición exigió abrir fichas a mano; el resto de este capítulo presenta ese resultado.

La muestra de 30 casos: diseño y resultado

Se construyó una muestra de 30 líneas con **cuotas de grupo fijadas antes de seleccionar**, extraídas de la muestra estratificada de 300, y se abrió cada una a mano contra el catálogo y contra el texto de la propia línea.

Diseño de la muestra, cierra 30/30, sin grupos cortos


Grupo	Qué selecciona	n	Disponibles antes de cuota
1 · sí estaba en la licitación	el código ONU de la OC sí figuraba en su licitación de origen	10	62
2 · no estaba en la licitación	el código ONU de la OC no figuraba en su licitación de origen	10	20
3 · licitación testimonial	varias líneas, un solo código distinto	5	17
4 · extremo de dispersión	extremos de precio dentro del mismo código	5	29

18 de 30 [MEDIDO] Los 30 códigos declarados existen en el catálogo obligatorio (100 %). Dieciocho de ellos (60,0 %) designan un producto distinto del que el texto de la línea dice que se compró; once (36,7 %) son consistentes y uno no admite veredicto de caso. **Un control de validez de formato, el que haría cualquier sistema, no detecta ninguno de esos 18.** Join determinístico contra datos/catalogo_onu_18881.csv, sin aleatoriedad, 6 de septiembre de 2026.

El problema de la capa de producto no es que los organismos usen códigos inválidos (los treinta que se abrieron a mano existen en el catálogo): es que **el código válido que declaran describe otra cosa**. Eso lo confirma un ser humano leyendo la ficha, no un algoritmo de similitud.

Veredicto final por grupo

Grupo	Consistente	Inconsistente	Salvedad	% consistente
1 · el código sí estaba en la licitación	6	4	n/d	60,0 %
2 · el código no estaba en la licitación	2	8	n/d	20,0 %
3 · licitación testimonial	1	4	n/d	20,0 %
4 · extremo de dispersión de precio	2	2	1	40,0 %
Total	11	18	1	36,7 %



Veredicto final por grupo, los 30 casos abiertos a mano

Veredicto final por grupo, los 30 casos abiertos a mano [MEDIDO]

- Consistente
- Inconsistente
- Salvedad metodológica (Convenio Marco)

Salvedad estadística: El contraste **60 % contra 20 %** apunta en la misma dirección que la Pregunta 1 (donde el dato existe, el dato es mejor) pero con **n = 10 por grupo no alcanza significancia: prueba exacta de Fisher, OR = 6,0, p = 0,170**. Este informe no afirma que la diferencia sea real. «p = 0,170» quiere decir que una diferencia así de marcada saldría por pura casualidad unas 17 veces de cada 100, aunque en el fondo no hubiera ninguna diferencia; el umbral con el que se acostumbra hablar de diferencia real es 5 de cada 100. Se declara la dirección, el n y el p, dejando explícito que la muestra no puede sostener más que eso.

Los cinco extremos de precio: el freno, ahora medido

Este grupo permite completar el análisis de la Pregunta 3. Abiertos los 5 casos, **2 declaran un código que designa una cosa de distinta naturaleza que la comprada**:

Los cinco extremos de dispersión, abiertos a mano

Texto de la línea	El código declarado designa	Lectura
«caldera para centro comunitario de salud familiar»	Dispositivo de encendido de calentador o caldera	una caldera completa codificada como su pieza de encendido
«4 plancha de cabello / 2 plancha de pelo»	Peluquerías y salones de belleza (un servicio)	un bien codificado como el servicio que lo usa
«tornillo mecánico somar base fija n 3» (Convenio Marco)	Tornillos de banco	salvedad metodológica, ver abajo
«presentación artística agrupación (...) en la plaza»	Servicios de músicos, banda u orquestas	consistente
«asistencia ventilatoria invasiva con TENS 12 hrs»	Servicios hospitalarios respiratorios	consistente

Lectura citable, con su n al lado: en los extremos de dispersión de precio, **2 de 5 casos abiertos a mano** declaran un código de naturaleza distinta a lo comprado (una pieza en vez del equipo completo, un servicio en vez del bien). **La dispersión de precio dentro de un mismo código mide heterogeneidad de producto, y ahora está verificada caso a caso, no solo argumentada.**

Con eso la Pregunta 3 **pasa a ser citable sin cambiar su conclusión**: no se responde en la dirección que se esperaba (no hay evidencia de sobreprecio, y no se afirma), se responde diciendo que **el código ONU no discrimina el producto lo suficiente para que la comparación de precios sea posible**. Es, además, la confirmación del hallazgo de §3.4.3 desde otro ángulo: **si el código no discrimina el producto, tampoco discrimina el precio. La Pregunta 3 no falla por falta de datos: falla por la misma razón que las otras tres.** Dato de contexto que ayuda a entender el techo del ejercicio: de los 51,45 millones de líneas, **12,05 millones no traen unidad de medida y 7,27 millones dicen literalmente «UNIDAD NO DEFINIDA».**

Freno doctrinal: Son **5 casos**. No es una tasa, no se extrapola a las celdas de dispersión (que tienen entre 12.537 y 30.070 líneas), **y no se nombra ningún organismo**. La tabla del proyecto trae el código de licitación y el de orden de compra (identificadores de documento público) pero **no se publican en este informe**, porque el prefijo del código identifica al organismo comprador. Están disponibles en el explorador del dashboard, etiquetados «alerta / requiere revisión», con enlace a la ficha original.

El caso que no recibe veredicto, y por qué eso es un hallazgo

Un caso de **Convenio Marco** no recibe veredicto de caso, y la razón no es una omisión. Su texto abre con **«1377597 tornillo mecánico somar base fija n 3 unidad 1404098...»**, es decir, con el identificador interno del catálogo, exactamente la firma que §3.4.3 documenta con 188 de 200 desacuerdos. En Convenio Marco **el comprador no digita el código ONU**: entra al catálogo, arma un carrito y compra; el código y el texto los puso el proveedor al cargar su producto. Un veredicto de «inconsistencia» sobre ese caso **atribuiría al comprador una decisión que no tomó.**

Se declara como **salvedad metodológica del diseño de la muestra**: los casos de Convenio Marco no son evaluables con este protocolo. Es 1 de 30 aquí, pero **Convenio Marco es el 17,6 % del volumen de líneas de 2026**: un protocolo que los excluye no puede hablar de ellos, y eso limita el alcance de este capítulo.

El control cruzado con un revisor externo, la tercera pata del patrón

Los 30 casos se pasaron también por una IA externa, fuera del entorno del proyecto, y su resultado se cruzó **uno por uno contra el catálogo**. Mantuvo el código declarado en 12 de 30 y propuso uno distinto en 18. **De esos 18, siete (38,9 %) son inutilizables**:

Las siete propuestas inutilizables del revisor externo, verificadas contra el catálogo [MEDIDO]

Tipo de falla	n	Detalle
No es un código de producto, es un IDCategoría (clase), no un código de 8 dígitos válido	2	40151500 «Bombas» y 40102000 «Calderas»
No existe en ningún nivel del catálogo	1	80161801 «Servicio de arriendo o leasing de impresoras»
El código existe, pero el nombre que le atribuye no es el del catálogo	4	42201512 lo llama «accesorios de conexión para medios de contraste» y el catálogo dice « mesas, repisas o sillas de tomografía »; 42151602 lo llama «prótesis dentales» y el catálogo dice « bandas para matriz dental »; 42151802 lo llama «alambres de ortodoncia» y el catálogo dice « perforadoras odontológicas »; 52141703 lo llama «planchas para el pelo» y el catálogo dice « secadores de pelo domésticos »

El veredicto sí/no del revisor externo acertó en los siete. El error está íntegramente en el *remedio*, nunca en el *diagnóstico*. **Regla operativa que queda establecida por este resultado**: ningún código sugerido por una IA (ni por una persona) se cita sin cruzarlo antes contra el catálogo, y el cruce se hace contra la columna de código de producto, no contra la de categoría.

La tercera pata, con las tres mediciones juntas, el diagnóstico es robusto, el remedio no

Fuente	Coincide en el diagnóstico	Coincide en el remedio
Tamiz léxico ↔ LSA, 300 líneas (§3.4.3)	222 de 300 dicen «ninguno» los dos	5,00 %
Revisor externo ↔ autor, 30 casos	acertó los 7 veredictos donde su código era inutilizable	38,9 % inutilizable
Autor ↔ catálogo, 2 casos	n/d	el catálogo no siempre tiene el código

Esto convierte la doctrina «alerta, no infracción» de postura ética en medición: el pipeline puede marcar, no puede corregir, y ahora hay tres números que lo respaldan.

La muestra completa

Las 30 líneas, en el orden de los grupos predeclarados. Sin código de licitación ni de orden de compra, por la doctrina de §2.1: su prefijo identifica al organismo comprador.

Los 30 casos, con el veredicto final humano [MEDIDO]

#	Texto de la línea, tal como lo escribió el comprador	Código ONU declarado	Veredicto final
Grupo 1 · sí estaba en la licitación			
1	por la reparacion de bomba y visita de emergencia por el sobrecalentamiento y trabajo forzado...	72131702 Construcción de obras civiles	inconsistente
2	servicio aseo dependencias direccion regional y cais punta arenas de marzo a diciembre 2018	76111501 Servicios de limpieza de edificios	consistente
3	320 entradas 3d y 320 servicio de confiteria entradas al cine y servicio de confiteria para ...	82131502 Procesamiento o reproducción de películas de cine	inconsistente
4	proyecto rnsf 19 ac 0001 en san felipe barrios mas organizados barrios mas seguros se oferta...	92121703 Alarmas	consistente
5	servicio de agua purificada en bidones mes de marzo 2021 se adjunta prefactura y pauta de ev...	83101504 Distribución de agua	consistente
6	adquisicion de cuarenta y cuatro 44 licencias arcserve udp v6 5 premium edition socket one y...	43232701 Software de servidor de aplicaciones	inconsistente
7	baterias cp12 9 baterias cp12 9	39121011 Fuentes de alimentación continua	inconsistente
8	disposicion final de residuos solidos variacion de ipc 12 8 valor neto mensual de servicio d...	76121501 Recolección, destrucción, transformación o eliminación de basuras	consistente
9	alambre de cobre eva tierra 2 5 mm2 alambre de cobre eva tierra 2 5 mm2	26121517 Hilo de cobre	consistente
10	desobstruccion de 3 camaras de alcantarillado inspeccion mediante varillas con rosco metalic...	81141807 Servicio de gasfitería y alcantarillado	consistente
Grupo 2 · no estaba en la licitación			
11	cambio de aceite segun ot adjunto n 104	15121501 Aceite de motor	inconsistente

#	Texto de la línea, tal como lo escribió el comprador	Código ONU declarado	Veredicto final
12	granadina mitjans granadina mitjans	50202303 Jugos y néctar concentrados	inconsistente
13	silicona delgada silicona delgada	13101708 Silicona VMQ y PMQ y PVMQ	inconsistente
14	guantes de cabritilla sin forro guantes de cabritilla sin forro	46181504 Guantes protectores	consistente
15	interruptor 9 12 matrones item n 98 interruptor 9 12 matrones	39111518 Luz de mano o de extensión	inconsistente
16	servicio de arriendo por 3 impresoras multifuncion correspondiente al periodo proporcional d...	43212110 Impresoras multifunción o multifuncionales	inconsistente
17	servicios de traslado estudiantes ralco el barco y viceversa mes octubre	20102301 Transportes de personal	inconsistente
18	ggt gamaglutamiltransferasa caja 250 det ggt gamaglutamiltransferasa caja 250 det	41116011 Reactivos de analizadores microbiológicos	inconsistente
19	metalcom estruc c 100x40x085x6mt metalcom estruc c 100x40x085x6mt	11101712 Aleación ferrosa	consistente
20	conector baja presion para jeringa de medio de contraste conector baja presion para jeringa ...	42201506 Inyectores de agentes de contraste de tomografía informatizada (TAC o CT) médica	inconsistente
Grupo 3 · licitación testimonial			
21	compra de 2 mediaguas 6x3 con piso y panel divisorio central para formar dos ambientes despa...	30201601 Casas	consistente
22	barras de prismas prismas en barra uno vertical uno horizontal marca luneau codigo 161239 se...	23151702 Equipo de medición de lentes	inconsistente
23	protesis dentales acrilicas programa odontologico integral 2019 ponente n 2 mas sonrisas par...	80111613 Mano de obra temporal	inconsistente
24	nitinol arco clasico inferior 016 preformado aleacion con memoria de forma tipo 3m orthoform...	30201903 Unidades dentales	inconsistente
25	pintura polane white segun anexo c pintura polane white segun anexo c	60121001 Pinturas	inconsistente
Grupo 4 · extremo de dispersión de precio			

#	Texto de la línea, tal como lo escribió el comprador	Código ONU declarado	Veredicto final
26	1377597 tornillo mecanico somar base fija n 3 unidad 1404098 1377597 tornillo mecanico somar...	27112102 Tornillos de banco	salvedad
27	contratar presentacion artistica agrupacion los jaivas el día viernes 17 de febrero de 2017 ...	82151704 Servicios de músicos, banda u orquestas	consistente
28	caldera para centro comunitario de salud familiar cecosf decreto n 1286 autoriza trato direc...	40101833 Dispositivo de encendido de calentador o caldera	inconsistente
29	asistencia ventilatoria invasiva con tens 12 hrs de lunes a domingo meses de agosto septiemb...	85101505 Servicios hospitalarios respiratorios	consistente
30	4 plancha de cabello italy elegance 2 plancha de pelo similar a air straight	91101701 Peluquerías y salones de belleza	inconsistente

Alcance y límites: No convierte los ratios de dispersión (36 a 268) en una cifra citable de sobreprecio, y con 5 casos abiertos no se podría aunque se quisiera. El contraste 60 % contra 20 % no es significativo ($p = 0,170$). Los casos de Convenio Marco no son evaluables con este protocolo. Y la ficha del outlier de 36,8 billones sigue sin poder abrirse. Los cuatro están declarados, no omitidos.

3.4.5 · Calidad del dato, cuatro defectos encontrados, medidos y acotados, dos de ellos propios

Un trabajo de datos que no encuentra defectos en sus datos no los buscó. Este capítulo reporta cuatro, y **dos son del propio corte de este proyecto**, no de la fuente. Ninguno mueve una cifra publicada, y esa afirmación está trazada en el código, no argumentada.

Códigos ONU malformados sobre 42.122.558 líneas evaluables

Forma	Líneas	%
Total malformadas	425.230	1,01 % del universo evaluable
Numérico de menos de 8 dígitos, casi todo el literal 0	423.231	99,53 % de las malformadas
Numérico de más de 8 dígitos	1.999	0,47 % de las malformadas
Nulos · solo ceros · notación decimal · no numérico	0	cero en las cuatro formas

Aclaración: «El 99,53 % es un cero» y «cero casos de solo-ceros» parecen contradecirse en la misma tabla. No se contradicen: el 0 de las 423.231 líneas es un **literal de un dígito**, mientras que «solo ceros» cuenta cadenas del tipo 00000000. Sin esta frase, un examinador ve una tabla que niega la cifra de la línea siguiente.

Cifra citable: una de cada cien líneas evaluables no trae código de producto, trae un cero. Los 1.999 códigos de nueve dígitos tienen forma de otra familia (104101001 con 1.456 líneas, 101101001 con 166, 102101001 con 152) compatible con un plan de cuentas o una codificación presupuestaria colada en el campo. Es **[POR VERIFICAR]** y son cuatro milésimas de punto porcentual del universo evaluable: vale una nota al pie, no una corrida.

Una partición del propio corte estaba inflada al triple

Al comparar el corte congelado del proyecto contra una re-descarga independiente, apareció un defecto **en el corte viejo**: la partición de licitaciones del año 2025 estaba inflada aproximadamente al triple. **Se midió con tres métodos independientes y los tres coincidieron en el orden de magnitud.**

La pregunta relevante es cuántas cifras publicadas se ven afectadas. La respuesta, trazada línea por línea en el código y no por argumento, es **ninguna**. La duplicación es del lado licitación; las cifras en pesos son del lado orden de compra; y ninguna cifra del régimen de evidencia lee las columnas afectadas. La confirmación llegó por un camino independiente: una re-descarga completa del lado orden de compra, procesada con el mismo pipeline, reproduce el corte congelado casi exactamente.

Re-descarga independiente del lado orden de compra contra el corte congelado [MEDIDO ×2]

Año	Filas re-descarga	Filas corte congelado	Delta	Duplicados exactos	Líneas/OC
2023	5.167.807	5.167.807	0,00 %	0	2,61
2024	5.343.656	5.344.111	-0,01 %	0	2,65
2025	5.141.750	5.150.919	-0,18 %	0	2,77

El factor tres del lado licitación no existe del lado orden de compra: las líneas por orden son estables y no hay un solo duplicado exacto en 36 archivos.

Salvedades: Los deltas son negativos. Una re-descarga posterior debería traer más filas, no menos. Las 9.169 filas de 2025 que estaban y ya no están son un 0,18 %, pero tienen el mismo signo que las 11.402 licitaciones ausentes documentadas abajo. Se declara la magnitud, no la causa.

La carpeta de la re-descarga no identifica sus archivos como órdenes de compra en el nombre; la evidencia interna es fuerte (2,6 líneas por documento contra 16,8 del lado licitación) pero conviene dejar constancia explícita. Si el informe cita «líneas por orden de compra», tiene que ser por año: la convergencia hacia 2,77 en 2025 es una tendencia real.

La columna de fecha de adjudicación no distingue lo estimado de lo observado

17,11 pp [MEDIDO] de brecha media entre el porcentaje de licitaciones con FechaAdjudicacion poblada y el porcentaje que efectivamente está en estado «Adjudicada», sobre 36 meses entre enero de 2023 y diciembre de 2025. Desviación estándar 1,57; rango 14,6 a 22,7. **Alrededor de una de cada seis licitaciones tiene fecha de adjudicación sin estar adjudicada.**

La brecha no decae con la edad del archivo: es igual de grande a los 43 meses que a los 12. Si fuera maduración (procesos que aún no cierran) se cerraría con el tiempo. No se cierra. **No es un archivo que madura, es una columna que se rellena.** Un indicador previo había medido que el 38,34 % de las fechas de un mes recién cerrado apuntan al futuro, y se había leído como que el borde reciente de la serie era dudoso. La lectura

correcta es más fuerte: **la columna no distingue en ninguna parte del período entre fecha estimada y fecha observada, y solo el borde reciente lo delata**, porque pasados unos meses la estimación queda en el pasado y se vuelve indistinguible de un hecho.

Un segundo dato refuerza que se trata de una convención de publicación: la completitud de esa columna vale **exactamente 100% en todos los meses desde agosto de 2024**, y entre 98,31 % y 99,94 % en todos los anteriores. Es un quiebre de formato en la fuente. **La completitud de esa columna, por lo tanto, no es evidencia de nada.**

Precisión: El centinela 1900-01-01 no aparece en la columna FechaAdjudicacion (la columna de este hallazgo), pero sí aparece como valor mínimo en otras cinco columnas de fecha (FechaEstimadaAdjudicacion, FechaSoporteFisico, FechaEstimadaFirma, FechaVisitaTerreno, FechaEntregaAntecedentes), con 31 publicaciones fechadas en 1900-01. Un documento interno del proyecto lo llama, correctamente, «el centinela de *sin fecha* de ChileCompra». Por lo tanto, el relleno de FechaAdjudicacion no se hace con ese centinela, y sigue abierto con qué valor se hace. La hipótesis natural es que se copie FechaEstimadaAdjudicacion, comprobable con un comando sobre un archivo. **[POR VERIFICAR]**

Una ventana de descarga, no un fenómeno del mercado

Quedan **11.402 licitaciones** presentes en el corte antiguo y ausentes de todo el corte nuevo. Su distribución en el tiempo descarta que sea un fenómeno de mercado: el déficit ocupa **doce meses contiguos, de noviembre de 2024 a octubre de 2025, plano en -9,80 %** con desviación de 1,1 puntos y bordes duros a ambos lados. Tres meses dan delta exactamente cero. **Una tasa constante con bordes duros es un evento de descarga, no una censura ni un cambio de comportamiento.** Se caracteriza por población, mes y estado, se declara, y no se persigue más allá.

Alcance de este hallazgo: La comparación entre los dos cortes calza dentro de medio punto para 2023 y para enero a octubre de 2024. No calza en el borde reciente: la salida cruda da **+1,34 % en mayo de 2026, +2,95 % en junio, +23,70 % en julio y +5.069 % en agosto**. Esto no contradice el hallazgo: es un fenómeno de signo contrario, porque el corte nuevo *agrega* licitaciones recién publicadas que el viejo no alcanzó a ver. El hallazgo se acota a los meses donde la comparación tiene sentido, y el borde reciente se identifica como lo que es: un archivo que todavía se está llenando.

3.4.6 · El método a prueba, cinco decisiones que empeoraron el resultado y se tomaron igual

Las cifras de este informe valen lo que valga el método que las produjo. Esta sección lista cinco decisiones metodológicas costosas, que en varios casos empeoraron el resultado.

1. Se midió el azar antes de celebrar una tasa. El 94,44 % de consistencia de la Pregunta 1 no significa nada sin el 1,38 % del baseline nulo permutado. La mayoría de los trabajos que reportan una tasa de coincidencia no reportan cuánto habría dado el azar sobre la misma distribución de códigos.

2. Se predeclararon placebos y se reportó cuando fallaron. La robustez de la Pregunta 2 incluye un placebo sobre pares de años sin intervención normativa, con criterio fijado antes de correr. Y el placebo del artículo 20 bis reveló algo incómodo que igual se publica: **la cobertura de un campo que la norma no manda se mueve igual que la del campo que sí manda**. El movimiento de la serie no es cumplimiento normativo.

3. Se descartó un resultado propio teniendo el número en la mano. Una implementación alternativa del tamiz de similitud (más rápida y más barata) se predeclará con un criterio de validación numérico: debía reproducir 30,57 % y 62,28 %. Reprodujo el segundo exacto y dio 15,24 % en el primero. **Se descartó entera, sin negociar el umbral**, aunque parte de ella sí replicaba y aunque el número ya estaba calculado.

Nota metodológica: una cifra válida que *también* aparece en la salida de la implementación descartada **se atribuye a la implementación válida, con su identificador de corrida**. Atribuirle a la descartada la vuelve incitable por la propia regla del proyecto. Se arregla re-atribuyendo, no borrando. La auditoría del 6 de septiembre encontró un caso de esto que quedaba sin resolver, ver el punto 4.

4. Se auditó el titular de las propias métricas. El tamiz de similitud se había titulado «el código declarado es el mejor de su familia: 30,57 %». Ese titular escondía que en el **62,28 %** de las líneas el método *no tenía opinión* (similitud cero con todos los códigos hermanos). El titular correcto es el condicional: **entre las líneas donde el método sí opinó, el declarado es el mejor en el 81,04 %**. Las dos cifras se citan siempre juntas.

Nota metodológica: el **81,04 %** es una derivada, no una cifra de corrida. El 81,04 % es $30,57 \div 37,72$. El 30,57 % y el 62,28 % se imprimen en la corrida válida; **el 37,72 %, su denominador, solo se imprime en el bloque de la implementación descartada**, que el propio proyecto prohíbe citar. Por lo tanto **el 81,04 % se cita como derivación declarada** ($100 - 62,28 = 37,72$; $30,57 / 37,72 = 81,04$), no como salida de corrida. La cifra no cambia; su marca sí.

Precisión: una cifra se retira del informe. Borradores anteriores afirmaban en el capítulo de limitaciones que un tercer método «opina en el 92,62 % de los pares». **El 92,62 % no aparece en ningún archivo del paquete de traspaso**. Se retira. Lo que sí se sostiene de esa comparación está en §4.2, sin ese número.

5. Se encontró un defecto propio, se midió y se acotó a cero. La partición inflada al triple de §3.4.5 es un defecto del propio corte. Se detectó con tres métodos independientes, se trazó su radio de daño inspeccionando qué código lee qué columna, y se demostró que no afecta ninguna cifra publicada. **No hubo que retractar nada. Hubo que declararlo.**

Lección metodológica: «el control de una corrida no es que termine sin error: **es que el insumo pueda contener el resultado que se busca.**» Tres herramientas correctas de este proyecto corrieron sobre insumos que no eran los suyos y devolvieron resultados limpios, plausibles y vacíos: una curva que salió plana porque le faltaban los meses en los que ocurre el fenómeno, y un bloque que anunció una hipótesis sostenida mirando la mitad de la evidencia que necesitaba.

Precisión: una cifra sin archivo no existe, aunque sea verdadera. La auditoría del 6 de septiembre encontró **cuatro identificadores de corrida citados sin un solo byte de salida archivada**. Uno se resolvió el mismo día: se recuperó la salida de CAP-3-BIS, se verificaron sus cuatro identidades aritméticas y se archivó (§2.4.3). **Los otros tres siguen sin archivo, y están declarados como tales en el Anexo A en vez de listados como corridas vigentes**. Las cifras que cuelgan de ellos no se retiran (son reproducibles y coherentes con el resto) pero **se citan diciendo que su salida no está archivada**. Es la diferencia entre un trabajo que declara sus huecos y uno al que se los encuentran.

4. Impacto Proyectado

La obligación de codificar existe; la verificabilidad, no.

4.1 · Logros y Beneficios

*Chile publica más datos de compras públicas que casi cualquier país de la región, y desde diciembre de 2024 tiene además una obligación legal explícita de clasificar y codificar cada bien y servicio transado. Este trabajo midió si esa combinación produce lo que promete, y la respuesta es que **no todavía**.*

Lo que se logró medir, y que no estaba medido antes

Los cinco logros del trabajo, y qué permite cada uno

Logro	Qué permite que antes no se podía
La primera medición nacional de la capa de producto , sobre la década completa y a nivel de línea	Cuantificar la verificabilidad del <i>qué</i> se compra, no solo del <i>a quién</i> : el ángulo que ni la literatura ni las quince reglas del Observatorio cubren
Un mecanismo identificado y aislado : el catálogo de Convenio Marco genera el texto de la especificación a partir del propio nombre del producto	Convertir un problema difuso de «calidad de datos» en un defecto de diseño concreto, con una solución de costo cercano a cero
Una asociación medida con la competencia : la discordancia de código duplica la probabilidad de oferente único ($OR_MH \approx 2,0$, con placebo limpio)	Responder a la objeción de que todo esto es «un problema de archivo». Tiene correlato observable en la competencia
Un límite del catálogo obligatorio, demostrado con el catálogo en la mano : para parte de lo que el Estado compra no existe código que lo describa	Distinguir «el organismo codificó mal» de «el catálogo no tiene dónde codificarlo»: dos problemas con soluciones opuestas
Un pipeline reproducible y auditado : 51,4 M de líneas, determinista en cinco corridas, reconciliado al 98,25 % contra la cifra oficial, con dos auditorías adversariales aplicadas	Que un tercero pueda repetir cada cifra desde la misma descarga pública, y encontrar los huecos ya declarados en vez de descubrirlos

Lo que se puede afirmar

Donde el dato existe, el dato es bueno. Cuando una orden de compra se puede comparar con la licitación que la originó, los códigos coinciden en el 94,44 % de los casos contra un 1,38 % del azar. No hay evidencia de codificación caprichosa.

Pero el dato casi nunca existe del lado que importa. El 80,08 % de las licitaciones declara a lo más un código de producto, y solo el 19,73 % del universo permite la comparación. La capa de producto se declara en la orden de compra (el documento que *ejecuta*) y no en la licitación (el documento que *compromete*).

La ley no cambió eso. El indicador se mueve 0,28 puntos porcentuales entre el último año sin obligación y el primero con ella, y sobrevive a las tres pruebas de robustez y al intervalo de confianza. El deterioro grande, de 10,22 puntos, ocurrió entre 2019 y 2022 y estaba consumado antes de la norma.

Hay un mecanismo responsable de la mayor parte del deterioro del texto. Convenio Marco pasa de 6,65 % a 99,86 % de líneas circulares y explica el 78 % de la circularidad de 2026 con el 17,6 % del volumen. No es una conducta de los compradores: **es la plataforma la que genera ese texto**.

Y abierto a mano, el problema tiene una forma precisa. De 30 casos revisados uno por uno, los 30 códigos declarados son válidos y 18 designan otra cosa. **La falla no es de formato: es de significado, y ningún control automático de validez la detecta.**

Qué haría falta para que esto se pudiera auditar

Las tres implicaciones que siguen son **propuestas del autor, no hallazgos**, y se etiquetan como tales. Las tres son de costo bajo y ninguna requiere cambiar la ley:

Impacto proyectado: tres cambios de costo bajo [PROPUESTA DEL AUTOR]

#	Propuesta	Qué desbloquea
1	Que la obligación de codificar alcance a la licitación , no solo a la orden de compra	Hoy el documento que compromete el gasto puede declarar un solo código para un contrato de miles de millones, y eso es formalmente suficiente. Sin este cambio, el 80,08 % no se mueve
2	Un campo booleano que marque el texto generado automáticamente por catálogo	Restauraría, a costo cercano a cero, la posibilidad de auditar la capa de producto de Convenio Marco: hoy es indistinguible de un texto escrito por una persona
3	Publicar el catálogo obligatorio versionado y fechado	Sin versión ni fecha de vigencia, ninguna auditoría de codificación sobre una serie histórica puede distinguir un error de un código retirado del catálogo después de la transacción

A las tres se agrega una cuarta, que este trabajo descubrió solo al abrir las fichas a mano y que no estaba en el plan: **el catálogo necesita un procedimiento para lo que no tiene código**. Cuatro revisores independientes no pudieron nombrar el código correcto de una entrada de cine. Mientras eso no exista, una fracción de las compras del Estado **no se puede codificar bien ni con la mejor voluntad**, y una auditoría que la marque como error estaría midiendo el catálogo, no al comprador.

Alcance y límites: ninguna cifra de este informe es una determinación de irregularidad. Son alertas estadísticas sobre la verificabilidad de lo publicado. Que una línea no sea auditable con datos abiertos no dice nada sobre si la compra fue correcta: dice que, **con lo que el Estado publica hoy, no se puede saber.**

4.2 · Mejoras Futuras

Esta sección cumple dos funciones: dice qué haría distinto una versión siguiente del trabajo, y **declara lo que este trabajo no puede afirmar**. Las dos cosas van juntas porque cada limitación es una mejora pendiente.

Las limitaciones que acotan lo ya publicado

- **«Circular» es una definición de este proyecto, no una categoría oficial.** Significa: el texto de especificación es una copia del nombre genérico del producto que trae el propio registro, o uno contiene al otro (el código está en §3.2). Cualquier lectura de las cifras de §3.4.3 depende de aceptar esa definición.

- **El catálogo obligatorio se publica sin versión ni fecha de vigencia [FUENTE]**, y su tamaño (18.881 códigos) es dato del archivo que este trabajo usó, no cifra oficial. Consecuencia: los códigos «fuera del catálogo» no se pueden distinguir entre error de codificación y código retirado.
- **Un mecanismo cuyo peso se derrumba y cuya tasa explota puede ser reclasificación, no cambio real.** Si parte de lo que en 2017 se emitía como Convenio Marco hoy se emite como Compra Ágil, la comparación es entre poblaciones distintas. Las mediciones de §3.4.3 no descartan esa posibilidad.
- **La causa técnica de la rampa de Convenio Marco es una hipótesis, no un hecho [POR VERIFICAR]**. La forma de la serie es compatible con una migración escalonada del catálogo, y se verificó que las renovaciones son por categoría y no en una fecha única, pero no hay una fecha de cambio de plataforma verificada.
- **La muestra de 300 líneas vale como 49,18 observaciones independientes por línea y 5,82 en pesos.** Toda cifra derivada va con el n efectivo del ponderador que corresponde. El error de la reponderación es de +0,34 % en conteo y **+15,40 % en pesos**: la cola es pesada y se declara.
- **Los montos no están deflactados.** El pipeline tiene el paso previsto pero desactivado por falta del archivo de IPC mensual empalmado. Las cifras en pesos son nominales.
- **La comparación de dos algoritmos de tamiz sobre los 200.000 pares queda abierta [POR VERIFICAR]**. Un método basado en embeddings entrenados sobre el propio corpus diverge fuertemente del léxico. **Ninguna de las dos cifras se cita junto a la otra hasta interpretar la divergencia**, y este informe no lo hace. *(La cifra concreta que borradores anteriores usaban aquí se retiró el 6 de septiembre por no tener respaldo archivado, ver §3.4.6.)*
- **El identificador de corrida exacto de dos cifras de la Pregunta 2 (85,24 % y 85,52 %) no está localizado.** La conclusión cualitativa tiene fuente alternativa trazable y reproducida; esos dos decimales puntuales, no.
- **Tres identificadores de corrida citados no tienen salida cruda archivada** en el paquete de traspaso (ver el Anexo A). Las cifras que cuelgan de ellos se citan declarando esa condición.
- **El módulo de cotejo que aportó evidencia complementaria es del mismo autor y de las mismas fuentes que el pipeline principal. No es validación externa**, y su muestra es de 71 hallazgos, una regla, un año, un mecanismo y 14 licitaciones. Ninguna tasa de ahí se extrapola.

Las mejoras, en orden de rentabilidad

Trabajo futuro: qué desbloquea cada uno y qué cuesta

Mejora	Qué desbloquea	Costo
Archivar las salidas crudas de las tres corridas que no las tienen	Que el 100 % de las cifras citadas cumpla la regla del propio proyecto	Una exportación por corrida
Determinar con qué valor se rellena FechaAdjudicacion cuando el estado no es «Adjudicada»	Cerrar §3.4.5 con mecanismo y no solo con magnitud: sería la mejor página de la sección	Un comando
Correr la concordancia caso a caso léxico ↔ transformer (hoy solo hay léxico ↔ LSA)	Que la consistencia entre arquitecturas sea de <i>caso</i> y no solo de <i>tasa</i>	15 min, si aparece el CSV por fila; re-correr el modelo si no

Mejora	Qué desbloquea	Costo
Ampliar los 30 casos a 100 o 150, con cuotas por mecanismo	Que el contraste 60 % vs 20 % alcance potencia estadística (hoy $p = 0,170$)	De 8 a 12 horas humanas
Un protocolo de revisión para Convenio Marco	Poder hablar del 17,6 % del volumen que el protocolo actual excluye por diseño	Diseño nuevo
Medir la pregunta simétrica: si la discordancia se asocia a licitaciones desiertas o canceladas	Extender la asociación con oferentes más allá de las adjudicadas	Una re-descarga
Deflactar por IPC mensual empalmado	Comparaciones de montos entre años	Un archivo de índice
Reentrenar N3 contra etiquetas humanas independientes	Hoy el modelo aprende de la codificación existente, no de la correcta: la etiqueta de nivel A mide acuerdo entre dos documentos, no acierto. Es la única forma de pasar de «reproduce el statu quo» a «propone el código correcto»	De 8 a 12 horas humanas de etiquetado, sobre la muestra estratificada ya construida

El clasificador supervisado, que se corrió el 7 de septiembre

El diseño del clasificador supervisado. El clasificador exige que la etiqueta de entrenamiento sea independiente del texto de entrada, para evitar la fuga por circularidad: si el modelo se entrena sobre texto circular, aprende a leer el nombre del código dentro de la propia descripción, y su exactitud alta no mide nada. La consideración de diseño de partida fue: *«un clasificador honesto necesita etiquetas humanas independientes, y este trabajo tiene 300 líneas con patrón oro y 30 fichas abiertas: suficiente para validar, insuficiente para entrenar»*. Esa consideración acierta en identificar la trampa de fuga de etiqueta, pero no en exigir que la etiqueta sea humana: la etiqueta necesita ser **independiente del texto con el que se entrena**, no necesariamente producida por una persona. Este trabajo cuenta con una fuente de etiquetas así: **las líneas de nivel A** (aquellas donde la licitación y la orden de compra, redactadas por separado y en momentos distintos, declaran exactamente el mismo código de ocho dígitos). Dos partes que coinciden de forma independiente. No son 300: son millones.

Embudo de etiquetas: de las líneas enlazadas al conjunto de entrenamiento [MEDIDO]

Filtro acumulado	Líneas	%
Líneas de orden de compra enlazadas, con código válido y con texto	15.318.366	100,00 %
Nivel A amplio: el código está en el conjunto que declaró su licitación	10.460.749	68,29 %
Nivel A estricto: la licitación declaró un solo código y la orden usa ese	5.973.071	38,99 %
Tras excluir el texto circular	5.766.247	96,54 % del estricto
Tras excluir el texto que trae el código escrito dentro	5.764.974	96,52 %

Filtro acumulado	Líneas	%
Tras excluir relleno y texto corto (= entrenable)	5.583.284	93,47 %

[MEDIDO] run_id 5a53ec4a1f30, 7 de septiembre de 2026: el mismo embudo reproduce las seis cifras exactas en la corrida previa fa2bca7b426b del mismo día

Las tres fugas que el diseño cierra, y por qué cada una importa

1 • Fuga por texto circular. La columna de nombre genérico del producto es el nombre de catálogo del código declarado. Usarla como variable de entrada sería entrenar al modelo a leer la respuesta dentro de la pregunta. El clasificador **no la usa nunca como entrada**, y además reutiliza el mismo filtro de circularidad de §3.2 (`_f_nocirc`, el que produce el 81,87 %) para descartar las líneas cuyo texto es una copia de ese nombre. Se descarta también el texto que trae el código escrito como literal a ocho, seis o cuatro dígitos.

2 • Fuga por repetición. El corpus tiene alrededor de 19,96 millones de pares distintos sobre 41,7 millones de líneas: la misma descripción aparece muchas veces. Un reparto aleatorio entre entrenamiento y prueba pondría copias de la misma línea a los dos lados, y lo que mediría sería memoria, no capacidad de generalizar. El diseño **deduplica por texto antes de repartir** (926.282 textos distintos) y **reparte por año, no al azar**: se entrena con datos de 2017 a 2023 y se evalúa sobre datos de 2024 a 2026, años que el modelo nunca vio. Un texto que aparece con dos segmentos distintos se descarta entero: es ruido irreducible.

3 • Fuga por métrica. Spark llama `f1` a la *F1 ponderada por soporte*, que sobre un catálogo de cola larga se ve bien y esconde justo lo que interesa. Las métricas de este bloque calculan la **macro-F1 a mano** (promediando por clase, no por volumen) y se validaron contra `scikit-learn` hasta el noveno decimal antes de correr nada.

El resultado

Predicción del segmento ONU (2 dígitos, 55 clases) desde el texto libre · prueba sobre 300.336 textos de 2024 a 2026 **[MEDIDO]**

Modelo	Accuracy	Baseline	Ganancia	macro-F1	F1 ponderado
NaiveBayes multinomial	57,44 %	15,62 %	+41,82 pp	0,4292	0,5885
LogisticRegression multinomial	63,93 %	15,62 %	+48,31 pp	0,4687	0,6287

[MEDIDO] run_id 5a53ec4a1f30 · Spark ML, `RegexTokenizer` → `StopWordsRemover(es)` → `CountVectorizer(20.000 términos, minDF 5)` → `IDF` → `StringIndexer` → clasificador · entrenamiento 625.946 textos, prueba 300.336 · salida cruda archivada en `resultados/cap18_n3_salida_cruda.txt`


La jerarquía UNSPSC se obtiene truncando el código, así que la misma pregunta se puede hacer un nivel más abajo: **familia, cuatro dígitos, 342 clases en vez de 55**. Se midió también, sobre el mismo conjunto de entrenamiento.

Predicción de la familia ONU (4 dígitos, 342 clases) · mismo train y test **[MEDIDO]**

Modelo	Accuracy	Baseline	Ganancia	macro-F1	F1 ponderado
--------	----------	----------	----------	----------	--------------

Modelo	Accuracy	Baseline	Ganancia	macro-F1	F1 ponderado
NaiveBayes multinomial	48,66 %	7,61 %	+41,05 pp	0,2481	0,4944
LogisticRegression multinomial	56,58 %	7,61 %	+48,97 pp	0,2739	0,5469

[MEDIDO] celda CAP-18-B sobre la tabla de entrenamiento de la corrida 5a53ec4a1f30, 7 de septiembre de 2026 · baseline = familia 7811 · 328 de las 342 clases aparecen en el conjunto de prueba. **Salvedad de trazabilidad: esta celda no acuñó identificador propio** y se cita por el de la tabla que consume



Clasificador N3: accuracy y macro-F1, segmento vs. familia

Clasificador supervisado N3 (LogisticRegression): accuracy y macro-F1, segmento vs. familia. [MEDIDO]

- Baseline (clase más frecuente)
- Accuracy
- macro-F1 (× 100, cifra honesta)

Nota metodológica: la ventaja sobre el azar es prácticamente la misma en los dos niveles (+48,31 pp en segmento, +48,97 pp en familia) y sin embargo la macro-F1 se cae a la mitad, de 0,4687 a 0,2739. No es una contradicción: es la definición misma del problema de cola larga. Al bajar de 55 clases a 342, lo que crece no es la dificultad de acertar en promedio, sino **la cantidad de clases raras sobre las que el modelo no tiene con qué aprender**. El accuracy casi no lo nota porque las clases raras aportan pocas líneas; la macro-F1 sí, porque les da el mismo peso que a las grandes.

De ahí sale la lectura operativa: **a nivel de segmento el modelo sirve para priorizar revisión; a nivel de familia, cada vez menos**. Y a ocho dígitos, 18.881 clases, no se intentó, por la misma razón por la que el diseño lo excluyó desde el principio.

Un control que se predeclará y que resultó necesario declarar, no aplicar

La tabla de entrenamiento se dedujo con el criterio de *segmento*: se conservaron los textos que apuntan a un único segmento de dos dígitos. Un texto puede cumplir eso y aun así apuntar a dos familias distintas dentro de ese segmento: **ruido de etiqueta que existe en el nivel de familia y no existía en el de segmento**. La celda no lo ignoró ni lo supuso pequeño: lo midió. Los textos que provienen de *una sola* línea de origen no pueden ser ambiguos por construcción, y son el **86,3 %** del conjunto de prueba (259.223 de 300.336). Evaluando por separado sobre ellos:

Control de contaminación de etiqueta en el nivel de familia [MEDIDO]

Modelo	macro-F1 test completo	macro-F1 test limpio	Diferencia
NaiveBayes	0,2481	0,2471	-0,0010
LogisticRegression	0,2739	0,2726	-0,0013

Las dos cifras coinciden hasta la milésima, así que la contaminación es inmaterial y se cita el test completo. El control se escribió *antes* de conocer el resultado y con el criterio de qué hacer en cada caso ya fijado (si las cifras hubieran diferido, se citaba el subconjunto limpio declarando por qué, y en ningún caso se promediaban las dos). Es la misma disciplina del umbral de ± 10 pp de §3.4.3 y del placebo de §3.4.1.

Nota metodológica: cómo leer estas cifras.

El baseline es predecir siempre la clase más frecuente del conjunto de entrenamiento (aquí el segmento 42, material médico). Acertaría el 15,62 % de las veces sin saber nada. Un accuracy sin ese número al lado no es una cifra, es una decoración: sobre un catálogo dominado por unos pocos segmentos, acertar la mitad podría no ser aprendizaje sino estructura del dato. Lo que se cita es la ganancia sobre el baseline: **+48,31 puntos porcentuales**.

La macro-F1 es la cifra honesta, precisamente porque es más baja. El F1 ponderado (0,6287) pesa cada clase por su volumen, así que unos pocos segmentos grandes y bien predichos lo levantan. La macro-F1 (0,4687) da a cada uno de los 55 segmentos el mismo peso, y por eso delata lo que el ponderado tapa: **la cola larga del catálogo se predice mal**. La brecha entre las dos cifras, 16 puntos, es la medida de ese problema, y está reportada en vez de escondida.

Comparación con la literatura: existe una referencia publicada sobre la misma tarea aplicada al clasificador europeo CPV que reporta un accuracy de 77,7 % con macro-F1 de 0,40 **[POR VERIFICAR]**. La tentación evidente es señalar que la macro-F1 de este trabajo (0,4687) es más alta. **Este informe no hace esa comparación como si fuera pareja, por dos razones.** Primero, esa cifra proviene del documento de evaluación inicial del proyecto y **no se re-verificó en la fuente primaria**, de modo que por el propio régimen de evidencia no puede citarse como hecho. Segundo, aunque se verificara, se trata de otro clasificador, otro idioma, otro corpus y otra granularidad: sirve para dimensionar el orden de magnitud esperable en esta familia de problemas, **no para declarar superioridad**.

Límites del modelo:

Que una línea en desacuerdo con el modelo esté mal codificada. Es una alerta estadística, y la macro-F1 dice exactamente cuánta desconfianza merece: el modelo se equivoca a menudo, sobre todo en los segmentos poco frecuentes. La doctrina de §2.1 no se relaja porque ahora exista un clasificador: **se apoya en él**: un modelo que acierta el segmento dos de cada tres veces puede priorizar qué mira un revisor, y no puede reemplazarlo.

Nada sobre el 18,13 % de líneas sin texto evaluable. El modelo no las ve por construcción: si no hay texto útil, no hay entrada. La parte del universo que este informe declara no auditable sigue siendo exactamente igual de no auditable.

Las tres limitaciones de este resultado, declaradas.

1 · La etiqueta mide acuerdo, no corrección. Nivel A dice que dos documentos coinciden, no que el código sea el correcto. Los 30 casos abiertos a mano (§3.4.4) muestran precisamente que un código puede ser válido, estar declarado de forma consistente y describir otra cosa. **El clasificador aprende la codificación existente, no la codificación correcta,** y esa distinción es la mejora pendiente número uno de la tabla siguiente.

2 · El conjunto de entrenamiento está sesgado, y el sesgo está medido. Nivel A estricto es el 38,99 % de las líneas candidatas: por construcción sobre-representa las compras de un solo producto, que son las más simples de describir y de codificar. El resultado no se extrapola al universo completo.

3 · Se midió hasta familia (4 dígitos), no hasta producto (8). A ocho dígitos son 18.881 clases y el diseño lo excluyó desde el principio: la tarea no es tratable con este volumen de etiquetas limpias, y reportar un accuracy bajo ahí no sería un hallazgo sino un error de diseño. **El nivel de producto queda fuera y se declara, no se estima.**

4 · La celda de familia no acuñó identificador de corrida propio y se cita por el de la tabla que consume (5a53ec4a1f30). Es una salvedad de trazabilidad, no de cálculo: la tabla de entrenamiento sí tiene identificador y está archivada. Se declara porque el propio régimen de evidencia de este trabajo lo exige.

5. Revisión y Comentario de los Integrantes

Qué me llevo de este proyecto

Sección del formato SIC · trabajo individual, un solo integrante

Revisión del integrante

Nombre	Revisión y comentario
Jeancarlo Cuesta (autor único)	Lo técnico fue lo más fácil. Spark, el particionado, los joins de 51 millones de líneas: eso se aprende y se depura. Lo difícil fue aprender a no afirmar. Este proyecto me obligó tres veces a botar trabajo que ya estaba hecho y que daba un número presentable: una implementación completa del tamiz de similitud que no pasó el criterio que yo mismo había fijado antes de correrla; un titular de métrica que sonaba muy bien («el código declarado es el mejor de su familia») y escondía que en el 62 % de los casos el método no tenía opinión; y una cifra de trazabilidad que llevaba semanas citando y que resultó ser un número escrito a mano dentro de un <code>print()</code> , sin ninguna celda que lo calculara. La lección concreta que me llevo es la que quedó escrita en §3.4.6: el control de una corrida no es que termine sin error, es que el insumo pueda contener el resultado que se busca. Tres veces me pasó que una herramienta correcta corriera sobre el insumo equivocado y devolviera algo limpio, plausible y vacío. Eso no lo detecta un test unitario. Y lo que más me sorprendió no fue un resultado del pipeline: fue abrir treinta fichas a mano y descubrir que los treinta códigos eran válidos y dieciocho describían otra cosa, y que en dos casos ni yo pude encontrar el código correcto en el catálogo obligatorio. Ahí entendí por qué la doctrina del proyecto tenía que ser «alerta, no infracción»: no es prudencia, es que el sistema no siempre tiene una respuesta correcta disponible.

6. Revisión y Comentario del Instructor

Para completar por el instructor

Sección del formato SIC · se entrega en blanco

Pauta de evaluación

Categoría	Puntaje	Revisión y comentario
IDEA	___ / 10	(a completar)
APLICACIÓN	___ / 30	(a completar)
RESULTADO	___ / 30	(a completar)
GESTIÓN DEL PROYECTO	___ / 10	(a completar)
PRESENTACIÓN E INFORME	___ / 20	(a completar)

Anexo A

Cifras citadas y su corrida de origen

Toda cifra **[MEDIDO]** de este informe proviene de una de las corridas siguientes. El identificador es el valor hexadecimal, no el nombre de la variable: el entorno reutiliza nombres de variable entre bloques.

Corridas con salida cruda archivada en el repositorio

Identificador	Fecha	Qué sostiene
1314c4f6d481	hasta el 20 de agosto de 2026	Cifras congeladas de P1, P2, P4 y el capítulo de dinero
fb7c3b125bf7	23 de agosto de 2026	Cascada de texto evaluable (G7); tamiz léxico sobre la muestra de 300; muestra estratificada
966ab5c4d538	24 de agosto de 2026	Circularidad por año y mecanismo; códigos malformados; re-corrida de la cascada
70680deaec66	26 de agosto de 2026	Primera corrida de confirmación de la Pregunta 1
04b96e79303b	26 de agosto de 2026	Tamiz de similitud reconfirmado; segundo algoritmo
770618aa84a4	28 de agosto de 2026	Auditoría del corte: licitaciones ausentes, ventana de descarga, inventario físico
corridas locales	del 28 al 29 de agosto de 2026	Perfil de órdenes de compra, brecha de fecha de adjudicación, curva de maduración
33251704e7f2	31 de agosto de 2026	Organismos entrantes en la ventana exacta del 12 de diciembre de 2024

Identificador	Fecha	Qué sostiene
		(§3.4.2): 56 organismos
5387564e7d37	1 de septiembre de 2026	CAP-3-BIS: G6 ajustado, 99,83 % (§2.4.3). Salida archivada el 6 de septiembre en resultados/cap3bis_g6_ajustado_salida_cruda.txt, con sus cuatro identidades aritméticas verificadas
bc06eb233fc5	3 de septiembre de 2026	CAP-14: asociación discordancia↔oferentes, Mantel-Haenszel + placebo (§3.4.1)
local, sin run_id	3 de septiembre de 2026	Concordancia léxico↔LSA caso a caso (§3.4.3); IC de Newcombe del Δ de P2 (§3.4.2); aritmética reproducible sobre corridas ya congeladas, sin Spark
local, sin run_id	6 de septiembre de 2026	Triage de los 30 casos (§3.4.4): join determinístico del .xlsx de revisión contra el catálogo, y prueba exacta de Fisher
5a53ec4a1f30	7 de septiembre de 2026	CAP-18: clasificador supervisado N3 (§4.2): embudo de etiquetas de nivel A y métricas de NaiveBayes y LogisticRegression sobre el segmento ONU. Su embudo de etiquetas reproduce las seis cifras exactas de la corrida previa fa2bca7b426b del mismo día. Salida archivada en resultados/cap18_n3_salida_cruda.txt. La celda CAP-18-B (familia, 4 dígitos) consume la tabla de entrenamiento de esta misma corrida y no acuña identificador propio : se cita por éste

Corridas citadas sin salida cruda archivada: declaradas por la auditoría del 6 de septiembre de 2026

Identificador	Qué sostiene	Qué falta
628c163f82e7	P1 reproducida y su cobertura ponderada; robustez del confundidor de P2; placebo; unidad de compra; contraste grande/chico; discrepancia_year	El identificador aparece solo en un documento de planificación del proyecto, no en un archivo de salida. Las cifras son coherentes con el resto y reproducibles, pero su salida no se puede señalar
86a9f215712a	Universo de licitaciones; G6 bruto 91,01 %; G6 restringido 66,97 % y por monto 70,24 %; efecto del truncamiento	Sin salida archivada aparte. Los dos insumos del G6 bruto (16.901.188 / 15.381.353) sí quedaron reproducidos exactos por el control interno de CAP-3-BIS , que está archivado
3cc62ce8efa7	Muestra estratificada (911 estratos, 41.696.043 líneas); corpus deduplicado y su costeo	Sin salida archivada. La muestra en sí sí está archivada como CSV, con sus 300 filas y sus pesos
sin run_id, fuera del entorno	Tamiz semántico con transformer multilingüe, 21,33 % (§3.4.3)	Ni run_id ni CSV por fila. Corrió fuera del entorno del proyecto el 26 de agosto y el archivo no se localizó. Declarado en la tabla de §3.4.3

Huecos abiertos al cierre de este informe: declarados, no resueltos

Pendiente	Bloquea	Costo
-----------	---------	-------

Pendiente	Bloquea	Costo
Archivar la salida de las tres corridas de la tabla anterior	Que el 100 % de las cifras cumpla §3.14 del propio proyecto	Una exportación por corrida
Con qué se rellena FechaAdjudicacion	Cerrar §3.4.5 con mecanismo, no solo magnitud	Un comando
La ficha del outlier de 36,8 billones en mercadopublico.cl	Nada: la cifra la sostiene el campo totalLineaNeto publicado	Devuelve error de servidor; declarado
Concordancia caso a caso léxico ↔ transformer	Que la consistencia entre arquitecturas sea de caso y no de tasa	15 min con el CSV; re-correr el modelo sin él
Interpretar la divergencia entre los dos algoritmos de tamiz sobre 200.000 pares	Nada: está declarado y acotado (§4.2)	Trabajo futuro
La causa de la brecha 56 vs. 217 organismos entrantes	Nada: la medición existe y NO CONVERGE, y está declarado (§3.4.2)	Trabajo futuro